

## 第三章 线性方程组解法

讲授：

大型线性方程组计算机求解的常用方法的构造和原理；


重点论述：

**Jacobi**迭代法、**Seidel**迭代法、**Guass**消元法及**LU**分解法的原理、构造、收敛性等。

## 第3章 线性方程组解法

### § 3.2 基本概念

线性方程组的解？  
迭代法？直接法？



## \*线性方程组的解

对于  $n$  个方程的  $n$ 元线性方程组

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \dots\dots\dots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n = b_n \end{cases} \quad (3.1)$$

式中  $a_{ij}$  称为系数,  $b_i$  称为右端项, 它们都是已知量;

若有  $x_1^*, x_2^*, \dots, x_n^*$  使方程组3.1成立, 则称

$x_1^*, x_2^*, \dots, x_n^*$  为方程组3.1的解。

$$Ax = b$$

其中  $A \in \mathbf{R}^{n \times n}, b \in \mathbf{R}^n, x \in \mathbf{R}^n$



## \*线性方程组的行列式解法

对于  $n$  个方程的  $n$  元线性方程组

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \dots\dots\dots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n = b_n \end{cases}$$

$$\text{令 } x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, b = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix}, B_j = \begin{pmatrix} a_{11} & \cdots & b_1 & \cdots & a_{1n} \\ a_{21} & \cdots & b_2 & \cdots & a_{2n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{n1} & \cdots & b_n & \cdots & a_{nn} \end{pmatrix} \quad (j = 1, 2, \dots, n)$$

其系数矩阵

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix}$$

$j$  列

如果  $|A| \neq 0$ , 则方程组  $Ax=b$  有唯一解

$$\text{且 } x_1 = \frac{|B_1|}{|A|}, x_2 = \frac{|B_2|}{|A|}, \dots, x_n = \frac{|B_n|}{|A|}.$$

方法很优美,

但可行性不好!



在数值计算中，解线性方程组的方法有  
直接法和迭代法两大类。

---

### 直接法

用计算公式直接计算出线性方程组的解的方法。

---

### 迭代法

用迭代公式来求满足精度要求的近似解的方法。

---



- 迭代法是一种逐次逼近线性方程组解的方法。



## 第3章 线性方程组解法

### § 3.3 线性方程组的迭代解法

$$x^{(k+1)} = Bx^{(k)} + g$$



## 基本思想

$$Ax = b \quad (4-1)$$

其中  $A \in \mathbf{R}^{n \times n}$ ,  $b \in \mathbf{R}^n$ ,  $x \in \mathbf{R}^n$

使用迭代法求解 (4-1) 时, 首先要将它变形, 变成如下形状的等价方程组

$$x = Bx + f \quad (4-2)$$

其中  $B \in \mathbf{R}^{n \times n}$ ,  $f \in \mathbf{R}^n$ ,  $x \in \mathbf{R}^n$

即 (4-1) 的解是 (4-2) 的解, 反之, (4-2) 的解也是 (4-1) 的解。用不同的方法构造 (4-2) 就可得到不同的迭代法。 (4-2) 中的矩阵  $B$  称为迭代矩阵。

如果已导出 (4-1) 的等价方程组 (4-2) 后, 计算 (4-1) 的解就变成求序列的极限.

取初始向量  $x^{(0)}$

代入 (4-2) 的右端. 其中,  $x = Bx + f$  (4-2)

$$x^{(1)} = Bx^{(0)} + f$$

$$x^{(2)} = Bx^{(1)} + f$$

$$x^{(3)} = Bx^{(2)} + f$$



其一般形式为

$$\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{f} \quad (k = 0, 1, 2, \cdots) \quad (4-3)$$

通常称使用（4-3）式求解的方法为迭代法，也称迭代过程或迭代格式。

如果对任意  $\mathbf{x}^{(0)}$ ，都有当  $k \rightarrow \infty$  时， $\mathbf{x}^{(k)} \rightarrow \mathbf{x}^*$ 。

其中  $\mathbf{x}^{(k)} = (\mathbf{x}_1^{(k)}, \mathbf{x}_2^{(k)}, \cdots, \mathbf{x}_n^{(k)})^T$ ， $\mathbf{x}^* = (\mathbf{x}_1^*, \mathbf{x}_2^*, \cdots, \mathbf{x}_n^*)^T$

也可写成

$$\lim_{k \rightarrow \infty} \mathbf{x}^{(k)} = \mathbf{x}^* \quad \text{即} \quad \lim_{k \rightarrow \infty} \mathbf{x}_i^{(k)} = \mathbf{x}_i^*, \quad i = 1, 2, \cdots, n$$

称该迭代法收敛，否则称迭代法发散。

由于

$$\lim_{k \rightarrow \infty} \boldsymbol{x}^{(k+1)} = \boldsymbol{B} \lim_{k \rightarrow \infty} \boldsymbol{x}^{(k)} + \boldsymbol{f}$$

所以收敛迭代法的极限向量  $\boldsymbol{x}^*$ ，满足

$$\boldsymbol{x}^* = \boldsymbol{B}\boldsymbol{x}^* + \boldsymbol{f}$$

即为方程组（4-2）的解，从而也是（4-1）的解。因此，使用迭代法求解就是求向量序列  $\boldsymbol{x}^{(0)}, \boldsymbol{x}^{(1)}, \boldsymbol{x}^{(2)}, \dots$  的极限向量  $\boldsymbol{x}^*$ 。

### 4.1.1 简单迭代法

简单迭代法也称基本迭代法，有些迭代法可以通过对基本迭代法的加速或变形而得到。设线性方程组的一般形式为

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n = b_n \end{cases}$$

其中矩阵  $A = (a_{ij})_{n \times n}$  为非奇异，且  $a_{ii} \neq 0$  ( $i = 1, 2, \dots, n$ )。

对上式移项和变形后可得等价的方程组：

## Jacobi 迭代格式

$$\left\{ \begin{array}{l} x_1 = \frac{1}{a_{11}} (b_1 - a_{12}x_2 - \cdots - a_{1n}x_n) \\ \vdots \\ x_i = \frac{1}{a_{ii}} (b_i - a_{i1}x_1 - \cdots - a_{ii-1}x_{i-1} - a_{ii+1}x_{i+1} - \cdots - a_{in}x_n) \\ \vdots \\ x_n = \frac{1}{a_{nn}} (b_n - a_{n1}x_1 - \cdots - a_{nn-1}x_{n-1}) \end{array} \right. \quad (4-4)$$

将 (4-4) 写成迭代格式, 即

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left[ b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij} x_j^{(k)} \right] \quad (i = 1, 2, \cdots, n) \quad (4-5)$$

## Jacobi 迭代格式

也可写成

$$x_i^{(k+1)} = x_i^{(k)} + \frac{1}{a_{ii}} \left[ b_i - \sum_{j=1}^n a_{ij} x_j^{(k)} \right] \quad (i = 1, 2, \dots, n) \quad (3-6)$$

迭代法（4-5）或（4-6）称为**Jacobi迭代法**。

## Jacobi 迭代格式

例1 将线性方程组

$$\begin{cases} 8x_1 - 3x_2 + 2x_3 = 20 & \Rightarrow x_1 = \frac{1}{8}(3x_2 - 2x_3 + 20) \\ 4x_1 + 11x_2 - x_3 = 33 & \Rightarrow x_2 = \frac{1}{11}(-4x_1 + x_3 + 33) \\ 2x_1 + x_2 + 4x_3 = 12 & \Rightarrow x_3 = \frac{1}{4}(-2x_1 - x_2 + 12) \end{cases}$$

解：写成Jacobi迭代格式（4-5）：

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij} x_j^{(k)} \right) \quad (i = 1, 2, \dots, n) \quad (4-5)$$

# Jacobi 迭代格式

$$\begin{cases} x_1^{(k+1)} = \frac{1}{8} (20 - 3x_2^{(k)} + 2x_3^{(k)}) \\ x_2^{(k+1)} = \frac{1}{4} (11 - x_1^{(k)} + x_3^{(k)}) \\ x_3^{(k+1)} = \frac{1}{4} (12 - 2x_1^{(k)} - x_2^{(k)}) \end{cases}$$

取初始向量  $\mathbf{x}^{(0)} = (0, 0, 0)^T$

$$x_1^{(1)} = \frac{20}{8}, \quad x_2^{(1)} = \frac{11}{4}, \quad x_3^{(1)} = \frac{12}{4} = 3 ;$$

## Jacobi 迭代格式

$$x_1^{(1)} = \frac{20}{8}, \quad x_2^{(1)} = \frac{33}{11} = 3, \quad x_3^{(1)} = \frac{12}{4} = 3 ;$$

$$x_1^{(2)} = \frac{1}{8}(20 + 3 \times 3 - 2 \times 3) \approx 2.875 \quad \dots, \quad x_1^{(10)} \approx 3.00032$$

$$x_2^{(2)} = \frac{1}{11}\left(33 + 4 \times \frac{20}{8} + 3\right) \approx 2.3636 \quad \dots, \quad x_2^{(10)} \approx 1.999838$$

$$x_3^{(2)} = \frac{1}{4}\left(12 - 2 \times \frac{20}{8} - 3\right) \approx 1 \quad \dots, \quad x_3^{(10)} \approx 0.999881$$

终止条件为： $\|x^{(k+1)} - x^{(k)}\| \leq \varepsilon$ 。精确解为： $x^* = (3, 2, 1)^T$ 。



## Seidel 迭代格式

在Jacobi迭代过程中，对已经算出来的信息未充分利用，在计算  $x_2^{(k+1)}$  时  $x_1^{(k+1)}$  已经算出，计算  $x_i^{(k+1)}$  时  $x_1^{(k+1)}, x_2^{(k+1)}, \dots, x_{i-1}^{(k+1)}$  已经算出。一般说来，后面的计算值  $x_i^{(k+1)}$  比前面的计算值  $x_i^{(k)}$  要精确些。故对Jacobi迭代法（4-5）可作如下改进.

$$\left\{ \begin{array}{l} x_1^{(k+1)} = \frac{1}{8}(20 + 3x_2^{(k)} - 2x_3^{(k)}) \\ x_2^{(k+1)} = \frac{1}{11}(33 - 4x_1^{(k)} + x_3^{(k)}) \\ x_3^{(k+1)} = \frac{1}{4}(12 - 2x_1^{(k)} - x_2^{(k)}) \end{array} \right. \quad \left\{ \begin{array}{l} x_1^{(k+1)} = \frac{1}{8}(20 + 3x_2^{(k)} - 2x_3^{(k)}) \\ x_2^{(k+1)} = \frac{1}{11}(33 - 4x_1^{(k+1)} + x_3^{(k)}) \\ x_3^{(k+1)} = \frac{1}{4}(12 - 2x_1^{(k+1)} - x_2^{(k+1)}) \end{array} \right.$$

## Seidel 迭代格式

取初始向量  $\mathbf{x}^{(0)} = (0,0,0)^T$ ，得到

$$x_1^{(1)} = 2.5$$

$$x_2^{(1)} = 3 - 0.363636 \times 2.5 \approx 2.0909091$$

$$x_3^{(1)} = 3 - 0.5 \times 2.5 - 0.25 \times 2.0909091 \approx 1.768939$$

$\vdots$

$$x_1^{(5)} \approx 2.999843, \quad x_2^{(5)} \approx 2.000072, \quad x_3^{(5)} \approx 1.000061。$$

终止条件为：  $\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\| \leq 10^{-5}$

## Seidel 迭代格式

将迭代格式可写成如下的分量形式，即

$$\left\{ \begin{array}{l} x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right) \\ k = 0, 1, 2, \dots; \\ i = 1, 2, \dots, n \end{array} \right. \quad (4-9)$$

称为**Gauss-Seidel**迭代法。

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij} x_j^{(k)} \right) \quad (i = 1, 2, \dots, n) \quad \textbf{Jacobi} \text{迭代}$$

## Sor法迭代格式

用Seidel迭代格式算出的 $x^{(k+1)}$ 记为 $\tilde{x}^{(k+1)}$ 得到

$\Delta x = \tilde{x}^{(k+1)} - x^{(k)}$ , 做加速处理:

$$x^{(k+1)} = x^{(k)} + \omega \Delta x = (1 - \omega) x^{(k)} + \omega \tilde{x}^{(k+1)}$$

得到Sor法迭代格式

$$x_i^{(k+1)} = (1 - \omega) x_i^{(k)} + \frac{\omega}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right)$$
$$i = 1, 2, \dots, n$$

**Sor法是Seidel迭代法的推广!**



例：写出如下程组的3种迭代格式

$$\begin{cases} 10x_1 - x_2 - 2x_3 = 7 \\ -x_1 + 10x_2 - x_3 = 8 \\ x_1 + x_2 - 5x_3 = -4 \end{cases}$$

**解：先写出不动点方程组：**

$$\begin{cases} x_1 = \frac{1}{10}(7 + x_2 + 2x_3) = 0.7 + 0.1x_2 + 0.2x_3 \\ x_2 = \frac{1}{10}(8 + x_1 + x_3) = 0.8 + 0.1x_1 + 0.1x_3 \\ x_3 = \frac{1}{5}(4 + x_1 + x_2) = 0.8 + 0.2x_1 + 0.2x_2 \end{cases}$$



Jacobi迭代格式:

$$\begin{cases} x_1^{(k+1)} = 0.7 + 0.1x_2^{(k)} + 0.2x_3^{(k)} \\ x_2^{(k+1)} = 0.8 + 0.1x_1^{(k)} + 0.1x_3^{(k)} \\ x_3^{(k+1)} = 0.8 + 0.2x_1^{(k)} + 0.2x_2^{(k)} \end{cases}$$

Seidel迭代格式:

$$\begin{cases} x_1^{(k+1)} = 0.7 + 0.1x_2^{(k)} + 0.2x_3^{(k)} \\ x_2^{(k+1)} = 0.8 + 0.1x_1^{(k+1)} + 0.1x_3^{(k)} \\ x_3^{(k+1)} = 0.8 + 0.2x_1^{(k+1)} + 0.2x_2^{(k+1)} \end{cases}$$

Sor迭代格式:

$$\begin{cases} x_1^{(k+1)} = (1-\omega)x_1^{(k)} + \omega(0.7 + 0.1x_2^{(k)} + 0.2x_3^{(k)}) \\ x_2^{(k+1)} = (1-\omega)x_2^{(k)} + \omega(0.8 + 0.1x_1^{(k+1)} + 0.1x_3^{(k)}) \\ x_3^{(k+1)} = (1-\omega)x_3^{(k)} + \omega(0.8 + 0.2x_1^{(k+1)} + 0.2x_2^{(k+1)}) \end{cases}$$



# 三种迭代法的向量迭格式

把  $Ax = b$  的  $A$  做分解： $A = D - L - U$

$$L = \begin{bmatrix} 0 & 0 & \cdots & 0 \\ -a_{21} & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ -a_{n1} & -a_{n2} & \cdots & 0 \end{bmatrix}, \quad U = \begin{bmatrix} 0 & -a_{12} & \cdots & -a_{1n} \\ 0 & 0 & \cdots & -a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 \end{bmatrix}$$

$$D = \begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{bmatrix}$$

## 观察Jacobi迭代法

$$x_i^{(k+1)} = -\frac{1}{a_{ii}} \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij} x_j^{(k)} + \frac{b_i}{a_{ii}} \quad (i = 1, 2, \dots, n)$$

则其矩阵的表示形式为：

$$\begin{pmatrix} x_1^{(k+1)} \\ x_2^{(k+1)} \\ \vdots \\ x_n^{(k+1)} \end{pmatrix} = \begin{pmatrix} 0 & -\frac{a_{12}}{a_{11}} & \dots & -\frac{a_{1n}}{a_{11}} \\ -\frac{a_{21}}{a_{22}} & 0 & \dots & -\frac{a_{2n}}{a_{22}} \\ \vdots & \vdots & \ddots & \vdots \\ -\frac{a_{n1}}{a_{nn}} & -\frac{a_{n2}}{a_{nn}} & \dots & 0 \end{pmatrix} \begin{pmatrix} x_1^{(k)} \\ x_2^{(k)} \\ \vdots \\ x_n^{(k)} \end{pmatrix} + \begin{pmatrix} \frac{b_1}{a_{11}} \\ \frac{b_2}{a_{22}} \\ \vdots \\ \frac{b_n}{a_{nn}} \end{pmatrix}$$



注意：

$$\begin{aligned}
 & \begin{matrix} B \\ \left( \begin{array}{cccc} 0 & -\frac{a_{12}}{a_{11}} & \cdots & -\frac{a_{1n}}{a_{11}} \\ -\frac{a_{21}}{a_{22}} & 0 & \cdots & -\frac{a_{2n}}{a_{22}} \\ \vdots & \vdots & \ddots & \vdots \\ -\frac{a_{n1}}{a_{nn}} & -\frac{a_{n2}}{a_{nn}} & \cdots & 0 \end{array} \right) \end{matrix} = \begin{matrix} D^{-1} \\ \left( \begin{array}{cccc} \frac{1}{a_{11}} & & & \\ & \frac{1}{a_{22}} & & \\ & & \ddots & \\ & & & \frac{1}{a_{nn}} \end{array} \right) \end{matrix} \begin{matrix} L+U \\ \left( \begin{array}{cccc} 0 & -a_{12} & \cdots & -a_{1n} \\ -a_{21} & 0 & \cdots & -a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ -a_{n1} & -a_{n2} & \cdots & 0 \end{array} \right) \end{matrix} \\
 & \begin{matrix} \left( \begin{array}{c} \frac{b_1}{a_{11}} \\ \frac{b_2}{a_{22}} \\ \vdots \\ \frac{b_n}{a_{nn}} \end{array} \right) \end{matrix} = \begin{matrix} D^{-1} \\ \left( \begin{array}{cccc} \frac{1}{a_{11}} & & & \\ & \frac{1}{a_{22}} & & \\ & & \ddots & \\ & & & \frac{1}{a_{nn}} \end{array} \right) \end{matrix} \begin{matrix} b \\ \left( \begin{array}{c} b_1 \\ b_2 \\ \vdots \\ b_n \end{array} \right) \end{matrix}
 \end{aligned}$$

则**Jacobi**迭代法可写成为：

$$\mathbf{x}^{(k+1)} = \mathbf{D}^{-1}(\mathbf{L} + \mathbf{U}) \mathbf{x}^{(k)} + \mathbf{D}^{-1}\mathbf{b}$$

$$x = D^{-1}(L + U)x + D^{-1}b$$

或者

$$Ax = b \Leftrightarrow (D - L - U)x = b$$

解出向量  $x$  得不动点方程组

$$x = D^{-1}(L + U)x + D^{-1}b$$

由此得 **Jacobi迭代的向量迭代格式**:

$$x^{(k+1)} = D^{-1}(L + U)x^{(k)} + D^{-1}b \quad (*)$$

**记:**  $B_J = D^{-1}(L + U), g_J = D^{-1}b$       **(\*) 式可以写为:**

$$x^{(k+1)} = B_J x^{(k)} + g_J$$

$B_J$ 称为Jacobi迭代矩阵



将Gauss-Seidel公式改写成

$$a_{ii}x_i^{(k+1)} = -\sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} + b_i \quad i = 1, 2, \dots, n$$

从而可写成矩阵形式为

$$\begin{matrix} \mathbf{D} \\ \begin{pmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{pmatrix} \end{matrix} \begin{pmatrix} x_1^{(k+1)} \\ x_2^{(k+1)} \\ \vdots \\ x_n^{(k+1)} \end{pmatrix} = \begin{matrix} \mathbf{L} \\ \begin{pmatrix} 0 & & & \\ -a_{21} & 0 & & \\ \vdots & \vdots & \ddots & \\ -a_{n1} & -a_{n2} & \dots & 0 \end{pmatrix} \end{matrix} \begin{pmatrix} x_1^{(k+1)} \\ x_2^{(k+1)} \\ \vdots \\ x_n^{(k+1)} \end{pmatrix} \\ + \begin{matrix} \mathbf{U} \\ \begin{pmatrix} 0 & -a_{12} & \dots & -a_{1n} \\ & 0 & \dots & -a_{2n} \\ & & \ddots & \vdots \\ & & & 0 \end{pmatrix} \end{matrix} \begin{pmatrix} x_1^{(k)} \\ x_2^{(k)} \\ \vdots \\ x_n^{(k)} \end{pmatrix} + \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix} \mathbf{b}$$

从而有  $\mathbf{D}\mathbf{x}^{(k+1)} - \mathbf{L}\mathbf{x}^{(k+1)} = \mathbf{U}\mathbf{x}^{(k)} + \mathbf{b}$

整理后可得

$$\mathbf{x}^{(k+1)} = (\mathbf{D} - \mathbf{L})^{-1} \mathbf{U}\mathbf{x}^{(k)} + (\mathbf{D} - \mathbf{L})^{-1} \mathbf{b}$$

$$\text{令 } \mathbf{B}_G = (\mathbf{D} - \mathbf{L})^{-1} \mathbf{U} \quad \mathbf{f}_G = (\mathbf{D} - \mathbf{L})^{-1} \mathbf{b}$$

$$\text{则 } \mathbf{x}^{(k+1)} = \mathbf{B}_G \mathbf{x}^{(k)} + \mathbf{f}_G \quad (k = 0, 1, \dots) \quad (4-10)$$

(4-10) 就是 Gauss-Seidel 迭代法。

**即有Seidel向量迭代格式：**

$$x^{(k+1)} = B_S x^{(k)} + g_s$$

$$B_S = (D - L)^{-1} U, \quad g_s = (D - L)^{-1} b$$

$B_S$ 为Seidel迭代矩阵

**Sor法向量迭代格式：**

$$x^{(k+1)} = B_\omega x^{(k)} + g_\omega$$

$$B_\omega = (D - \omega L)^{-1} [(1 - \omega) D + \omega U], \quad g_\omega = (D - \omega L)^{-1} b$$

**上面三种向量迭代格式可以写成一种：**

$$x^{(k+1)} = Bx^{(k)} + g$$

,  $B$ 为迭代矩阵



# 迭代法的收敛性

我们要考虑如下问题：

- ① 如何判断迭代过程是否收敛呢？
- ② 迭代格式收敛的充要条件、充分条件是什么？
- ③ 决定迭代收敛速度的因素是什么？

定义3. 1: 若  $\lim_{k \rightarrow \infty} x_i^{(k)} = x_i^*, \forall i$ , 称向量序列  $x^{(k)}$  收敛于向量  $x^*$ ,

简记为  $\lim_{k \rightarrow \infty} x^{(k)} = x^*$

这里  $x^{(k)} = \left( x_1^{(k)}, x_2^{(k)}, \dots, x_n^{(k)} \right)^T$ ,  $x^* = \left( x_1^*, x_2^*, \dots, x_n^* \right)^T$

设某种迭代格式为

$$\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{f}$$

且该线性方程组的精确解为  $\mathbf{x}^*$ ，则

$$\mathbf{x}^* = \mathbf{B}\mathbf{x}^* + \mathbf{f}$$

两式相减，得

$$\mathbf{x}^{(k+1)} - \mathbf{x}^* = \mathbf{B}\mathbf{x}^{(k)} - \mathbf{B}\mathbf{x}^* = \mathbf{B}(\mathbf{x}^{(k)} - \mathbf{x}^*) = \cdots = \mathbf{B}^{k+1}(\mathbf{x}^{(0)} - \mathbf{x}^*)$$

令  $\boldsymbol{\varepsilon}^{(k)} = \mathbf{x}^{(k)} - \mathbf{x}^*$ ，则

$$\boldsymbol{\varepsilon}^{(k+1)} = \mathbf{B}\boldsymbol{\varepsilon}^{(k)} = \mathbf{B}^2\boldsymbol{\varepsilon}^{(k-1)} = \cdots = \mathbf{B}^{k+1}\boldsymbol{\varepsilon}^{(0)}$$

故当  $\lim_{k \rightarrow \infty} \boldsymbol{\varepsilon}^{(k+1)} = \mathbf{0}$  时， $\lim_{k \rightarrow \infty} \boldsymbol{\varepsilon}^{(k+1)} = \lim_{k \rightarrow \infty} (\mathbf{B}^{k+1}\boldsymbol{\varepsilon}^{(0)}) = \mathbf{0}$

而  $\boldsymbol{\varepsilon}^{(0)} = \mathbf{x}^{(0)} - \mathbf{x}^*$  是一个非零的常向量，因此只有

$$\lim_{k \rightarrow \infty} \mathbf{B}^{k+1} = \mathbf{O}_{n \times n} \quad (\text{零矩阵})$$

## 为研究收敛，分析向量、矩阵及其运算的性质，引入刻画的“距离”的概念---范数

定义3.2 设 $L$ 是数域 $K$ 上的一个线性空间，如果定义在 $L$ 上的实值函数 $P(x)$ 满足：

$$1) \forall x \in L \Rightarrow P(x) \geq 0, P(x) = 0 \Leftrightarrow x = 0;$$

非负性

$$2) \forall x \in L, \lambda \in K \Rightarrow P(\lambda x) = |\lambda| P(x);$$

齐次性

$$3) \forall x, y \in L \Rightarrow P(x + y) \leq P(x) + P(y)$$

三角不等式

则称 $P(\cdot)$ 是 $L$ 上的一个范数，称 $P(x)$ 为 $x$ 的一个范数。

记 $P(x) = \|x\|_p = \|x\|$ ，定义的3条可以写为

$$1) \|x\| \geq 0 \text{ 且 } \|x\| = 0 \Leftrightarrow x = 0;$$

$$2) \|\lambda x\| = |\lambda| \|x\|;$$

$$3) \|x + y\| \leq \|x\| + \|y\|$$

与绝对值比较

$$1) |x| \geq 0 \text{ 且 } |x| = 0 \Leftrightarrow x = 0;$$

$$2) |\lambda x| = |\lambda| |x|;$$

$$3) |x + y| \leq |x| + |y|$$





# 数值分析中常用的线性空间

## 1、 $n$ 维向量空间

$$R^n = \{a \mid a = (a_1, a_2, \dots, a_n), a_k \in R\}$$

## 2、矩阵空间

$$R^{m \times n} = \left\{ A_{m \times n} \mid A_{m \times n} = (a_{ij})_{m \times n}, a_{ij} \in R \right\}$$

## 3、连续函数空间

$$C[a, b] = \{f(x) \mid f(x) \text{ 在 } [a, b] \text{ 上连续} \}$$

## 线性运算定义:

$$f + g: (f + g)(x) = f(x) + g(x)$$

$$\lambda f: (\lambda f)(x) = \lambda \cdot f(x), \lambda \text{ 为数}$$



## 数值分析中常用的范数

1、  $R^n$  中的向量范数  $x = (x_1, x_2, \dots, x_n)^T$

$$1) \quad \|x\|_1 = \sum_{k=1}^n |x_k|$$

$x = (1, 2, -3)^T$ , 则有

$$\|x\|_1 = |1| + |2| + |-3| = 6;$$

$$2) \quad \|x\|_2 = \sqrt{\sum_{k=1}^n x_k^2}$$

$$\|x\|_2 = \sqrt{|1|^2 + |2|^2 + |-3|^2} = \sqrt{14};$$

$$3) \quad \|x\|_\infty = \max_{1 \leq k \leq n} |x_k|$$

$$\|x\|_\infty = \max\{|1|, |2|, |-3|\} = 3$$

$$\|x\|_p = \left( \sum_{i=1}^n |x_i|^p \right)^{1/p}, \quad 1 \leq p < +\infty$$

分别称为 1, 2,  $\infty$  范数和  $p$ -范数。



前面三种范数都为 $p$ -范数，当  $p = 1, 2, \infty$  时的范数。

注意，当时  $p \rightarrow \infty$ ， $\|\mathbf{x}\|_p \rightarrow \|\mathbf{x}\|_\infty$ 。事实上，

$$\|\mathbf{x}\|_\infty^p = \max_{1 \leq i \leq n} |\mathbf{x}_i|^p \leq \sum_{i=1}^n |\mathbf{x}_i|^p \leq n \cdot \max_{1 \leq i \leq n} |\mathbf{x}_i|^p = n \cdot \|\mathbf{x}\|_\infty^p$$

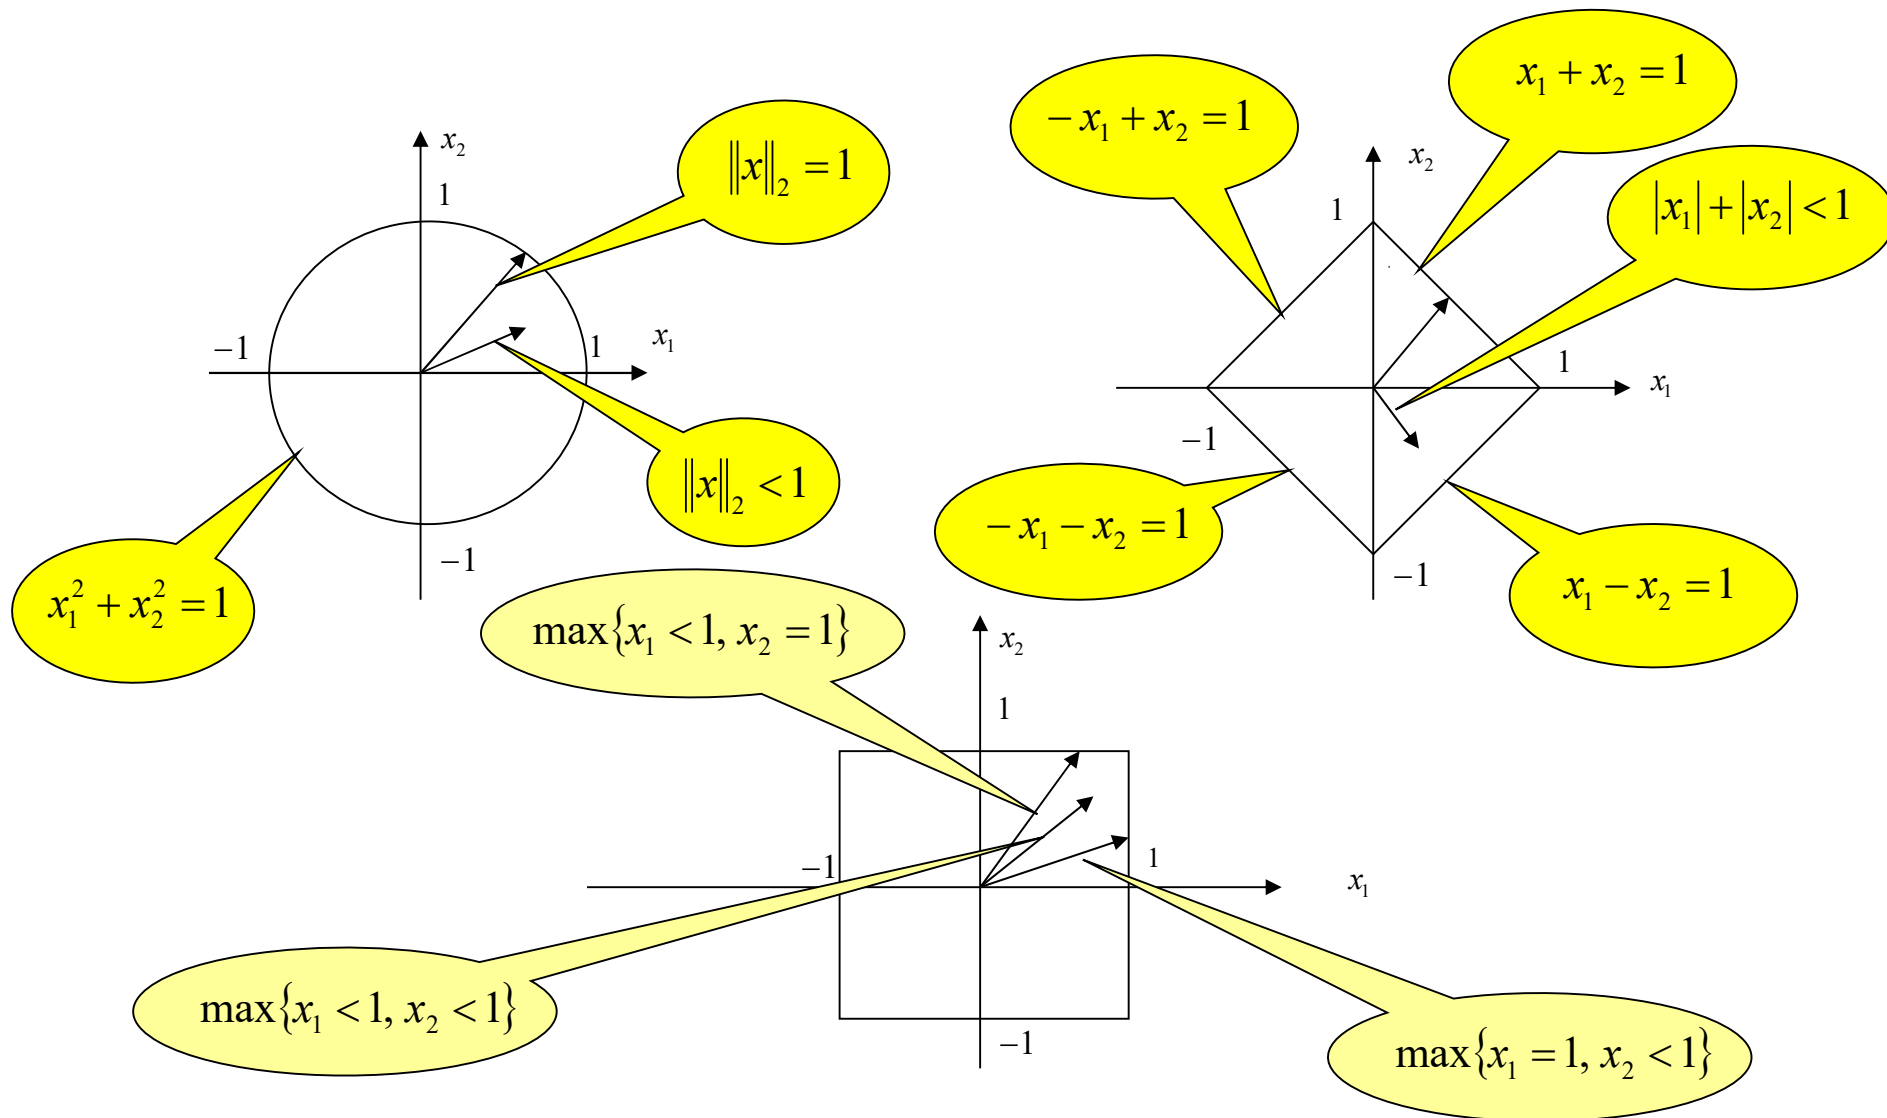
两边开 $p$ 次方得

$$\|\mathbf{x}\|_\infty \leq \left( \sum_{i=1}^n |\mathbf{x}_i|^p \right)^{\frac{1}{p}} \leq n^{\frac{1}{p}} \cdot \|\mathbf{x}\|_\infty, \text{ 由于 } \lim_{p \rightarrow \infty} \sqrt[p]{n} = 1, \text{ 故 } \|\mathbf{x}\|_p \rightarrow \|\mathbf{x}\|_\infty$$

容易验证以上三种范数均满足范数定义中的三个条件。

下面我们分析向量的  $1, 2$  和  $\infty$ -范数的几何意义，

为此，不妨设  $x = (x_1, x_2)^T \in \mathbf{R}^2$ ,  $\|x\|_2 \leq 1$ ,  $\|x\|_\infty \leq 1$  和  $\|x\|_1 \leq 1$ 。



一般情况下，对给定的任意一种向量范数 $\|\cdot\|$ ，可定义出加权的范数： $\|\mathbf{x}\|_w = \|W\mathbf{x}\|$  其中 $W$ 为对角矩阵，其对角元素是它的每一个分量的权系数。例如，对任  $\mathbf{x} = (x_1, x_2, x_3)^T \in \mathbf{C}^3$

$$W = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & -2 \end{pmatrix} \in \mathbf{C}^{3 \times 3},$$

加权的1-范数为：

$$\|\mathbf{x}\|_w = \|W\mathbf{x}\|_1 = \left\| \begin{pmatrix} 1 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & -2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} \right\|_1 = |x_1| + 3|x_2| + 2|x_3|$$

加权的2-范数为：

$$\|\mathbf{x}\|_w = \|W\mathbf{x}\|_2 = \left( |x_1|^2 + 9|x_2|^2 + 4|x_3|^2 \right)^{1/2}$$

例 对任给  $\mathbf{x} = (x_1, x_2, x_3)^T \in \mathbb{C}^3$ , 试问如下实值函数是否构成向量范数?

1.  $|x_1| + |2x_2 + x_3|$ , ✗

2.  $|x_1| + |2x_2| - 5|x_3|$ , ✗

3.  $|x_1|^4 + |x_2|^4 + |x_3|^4$ , ✗

4.  $|x_1| + 3|x_2| + 2|x_3|$  ✓

答: 1. 中取  $x_1 = 0, x_3 = -2x_2$       2. 中取  $x_1 = 0, x_3 = \frac{2}{5}x_2$

故, 1. 和 2. 不满足非负性条件。

3. 不满足齐次性条件;

$$\begin{aligned} f(\alpha \mathbf{x}) &= |\alpha x_1|^4 + |\alpha x_2|^4 + |\alpha x_3|^4 \\ &= |\alpha|^4 (|x_1|^4 + |x_2|^4 + |x_3|^4), \end{aligned}$$

4. 满足加权向量范数的定义, 故构成向量范数。

## 矩阵范数

若我们取

$$E_{ij} = \begin{pmatrix} 0 & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \cdots & \vdots \\ 0 & \cdots & 1 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 0 \end{pmatrix}$$

↑ 第*j*列

→ 第*i*行

则 $E_{ij}$ 线性无关，而且任意一个 $m \times n$  矩阵  $A = (a_{ij})$  都可表为：

$$A = \sum_{i=1}^m \sum_{j=1}^n a_{ij} E_{ij}$$

这也就是说，全体 $m \times n$  矩阵构成的空间的维数是 $mn$ 。因此， $\mathbf{R}^{m \times n}$ 亦可看作一个 $mn$ 维的向量空间。这样，我们自然想到将向量范数的概念直接推广到矩阵上。然而这种推广应考虑到矩阵的乘法运算。因而使用的矩阵范数的定义是按如下方式。

**定义1.5** 定义在 $\mathbf{C}^{m \times n}$ 上的一个非负实值函数，记为

$f(A) = \|A\|$ ，若该函数满足以下条件：

即对任意矩阵 $A$ 、 $B$ 以及任意复常数  $\alpha \in \mathbf{C}$

(1) 非负性  $\|A\| \geq 0$  当且仅当  $A = \mathbf{0}_{m \times n}$  时  $\|A\| = 0$

(2) 齐次性  $\|\alpha A\| = |\alpha| \cdot \|A\|$

(3) 三角不等式  $\|A + B\| \leq \|A\| + \|B\|$

(4) 相容性  $\|AB\| \leq \|A\| \cdot \|B\| \quad A \in \mathbf{C}^{m \times l}, B \in \mathbf{C}^{l \times n}$

则称函数  $\|\cdot\|$  为 $\mathbf{C}^{m \times n}$ 上的一个矩阵范数。

便于分离变量，  
缩放估计，  
瓶子能装多少东西？  
单独装沙或装水  
或混合装



$$\|A\|_{m_1} = \sum_{i=1}^m \sum_{j=1}^n |a_{ij}| \quad (1-23)$$

$$\|A\|_F = \left( \sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2 \right)^{\frac{1}{2}} \quad (1-24)$$

显然上述两个函数均满足矩阵范数定义中的（1）—（3）  
我们分别称由（1-23）和（1-24）所定义的范数为矩阵的  
 $m_1$ -范数和Frobenius范数（简称F-范数）。

性质：

$$\|A\|_{m_1} = \sum_{i=1}^n \|\mathbf{a}_i\|_1$$

$$\|A\|_F = \left( \sum_{i=1}^n \|\mathbf{a}_i\|_2^2 \right)^{1/2}$$

$$\|A\|_F = \left( \text{tr}(A^H A) \right)^{1/2}$$

其中  $\mathbf{a}_i$  为  $A$  的  $i$  列

下面证明 (1-23) 满足相容条件, 证: 由定义

$$\begin{aligned}\|\mathbf{AB}\|_{m_1} &= \sum_{i=1}^m \sum_{j=1}^n \left| \sum_{k=1}^l a_{ik} \cdot b_{kj} \right| \\&= \sum_{i=1}^m \sum_{j=1}^n \left| a_{i1}b_{1j} + a_{i2}b_{2j} + \cdots + a_{il}b_{lj} \right| \\&\leq \sum_{i=1}^m \sum_{j=1}^n \left( |a_{i1}b_{1j}| + |a_{i2}b_{2j}| + \cdots + |a_{il}b_{lj}| \right) \\&\leq \sum_{i=1}^m \sum_{j=1}^n \left( |a_{i1}| + |a_{i2}| + \cdots + |a_{il}| \right) \cdot \left( |b_{1j}| + |b_{2j}| + \cdots + |b_{lj}| \right) \\&= \left( \sum_{i=1}^m \sum_{k=1}^l |a_{ik}| \right) \left( \sum_{k=1}^l \sum_{j=1}^n |b_{kj}| \right) = \|\mathbf{A}\|_{m_1} \|\mathbf{B}\|_{m_1}\end{aligned}$$

下面证明 (1-24) 满足相容条件, 证: 记

$$AB = \begin{pmatrix} A_1 \\ A_2 \\ \vdots \\ A_m \end{pmatrix} (B_1 \quad B_2 \quad \cdots \quad B_n) = \begin{pmatrix} A_1 B_1 & A_1 B_2 & \cdots & A_1 B_n \\ A_2 B_1 & A_2 B_2 & & A_2 B_n \\ \vdots & \vdots & \ddots & \vdots \\ A_m B_1 & A_m B_2 & \cdots & A_m B_n \end{pmatrix}$$

其中  $A_i = (a_{i1}, a_{i2}, \dots, a_{in}) \quad i = 1, 2, \dots, m$   
 $B_j = (b_{1j}, b_{2j}, \dots, b_{nj})^T \quad j = 1, 2, \dots, n$

$$(A_i^T B_j) = A_i B_j = \sum_{k=1}^l a_{ik} b_{kj}$$

$$\begin{aligned} \|AB\|_F &= \sqrt{\sum_{i=1}^m \sum_{j=1}^n \left| \sum_{k=1}^l a_{ik} b_{kj} \right|^2} = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |A_i B_j|^2} \leq \sqrt{\sum_{i=1}^m \sum_{j=1}^n \left( \|A_i\|_2^2 \|B_j\|_2^2 \right)} \\ &= \sqrt{\sum_{i=1}^m \|A_i\|_2^2} \sqrt{\sum_{j=1}^n \|B_j\|_2^2} = \|A\|_F \|B\|_F \end{aligned}$$

例 设  $A = (a_{ij})_{m \times n} \in \mathbf{C}^{m \times n}$ ,  $f(A) = \max_{ij} |a_{ij}|$ , 问是否构成  $A$  的一种范数?

解: 取  $A = \begin{pmatrix} 1 & 1 \\ 0 & 0 \\ 0 & 0 \end{pmatrix}$ ,  $B = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \end{pmatrix}$ , 那么,  $AB = \begin{pmatrix} 2 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}$ ,

则可得出

$$f(A) = f(B) = 1, \quad f(AB) = 2, \quad \text{从而有}$$

$f(AB) > f(A) \cdot f(B)$ , 故不构成  $A$  的一种范数。

若定义实值函数:  $\|A\| = \sqrt{m \cdot n} \cdot \max_{ij} |a_{ij}|$ , 则可验证其构成  $A$  的一种范数。

**定理1.2** (向量范数的等价性定理) 设  $\|\cdot\|_\beta$  和  $\|\cdot\|_\alpha$  为  $\mathbf{C}^n$  上的任意两种向量范数, 则存在两个与向量无关的正常数  $c_1 > 0$  和  $c_2 > 0$ , 使得下面的不等式成立

$$c_1 \|\mathbf{x}\|_\beta \leq \|\mathbf{x}\|_\alpha \leq c_2 \|\mathbf{x}\|_\beta \quad (1-6)$$

并称  $\|\cdot\|_\alpha$  和  $\|\cdot\|_\beta$  为  $\mathbf{C}^n$  上的等价范数。

利用定理1.1可证如下的重要的结果

**定理** (向量序列收敛性定理) 设  $\mathbf{x}_k \in \mathbf{C}^n$ , 则

$$\lim_{k \rightarrow \infty} \|\mathbf{x}_k - \mathbf{x}\| = 0 \iff \lim_{k \rightarrow \infty} |x_i^{(k)} - x_i| = 0, \quad i = 1, 2, \dots, n \quad \left( \lim_{k \rightarrow \infty} \mathbf{x}_k = \mathbf{x} \right)$$

其中  $\mathbf{x}_k = (x_1^{(k)}, x_2^{(k)}, \dots, x_n^{(k)})^T$ ,  $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$ 。

## 矩阵范数具有向量范数的一切性质

### 定理

(矩阵范数的等价性定理) 设  $\|\cdot\|_\beta$  和  $\|\cdot\|_\alpha$  为  $\mathbf{C}^{m \times n}$

上的任意两种矩阵范数, 则存在两个与矩阵无关的正常数  $C_1 > 0$  和  $C_2 > 0$ , 使得下面的不等式成立

$$c_1 \|A\|_\beta \leq \|A\|_\alpha \leq c_2 \|A\|_\beta$$

并称  $\|\cdot\|_\alpha$  和  $\|\cdot\|_\beta$  为  $\mathbf{C}^{m \times n}$  上的等价范数。

### 定理

(矩阵序列收敛性定理) 设  $A_k \in \mathbf{C}^{m \times n}$ , 则

$$\lim_{k \rightarrow \infty} \|A_k - A\| = 0 \iff \lim_{k \rightarrow \infty} \left| a_{ij}^{(k)} - a_{ij} \right| = 0, \begin{matrix} i = 1, 2, \dots, m \\ j = 1, 2, \dots, n \end{matrix} \quad \left( \lim_{k \rightarrow \infty} A_k = A \right)$$

其中  $A_k = (a_{ij}^{(k)})$ ,  $A = (a_{ij}) \in \mathbf{C}^{m \times n}$ 。

矩阵与向量的乘积在矩阵计算中经常出现，所以我们自然希望矩阵范数与向量范数之间最好有某种协调性。若将向量看作矩阵的特殊情形，那么由矩阵范数的相容性，我们便得到了这种协调性，即矩阵范数与向量范数的相容性。

**定义1.6** 对于一种矩阵范数  $\|\cdot\|_M$  和一种向量范数  $\|\cdot\|_V$  如果对任意  $m \times n$  矩阵  $A$  和任意  $n$  维向量  $x$ ，满足

$$\|Ax\|_V \leq \|A\|_M \|x\|_V$$

则称矩阵范数  $\|\cdot\|_M$  与向量范数  $\|\cdot\|_V$  是相容的。

矩阵  $m_1$  范数与向量的  $p$ -范数是相容的，即  $\|Ax\|_p \leq \|A\|_{m_1} \|x\|_p$

而矩阵的  $F$ -范数与向量的  $2$ -范数是相容的，即  $\|Ax\|_2 \leq \|A\|_F \|x\|_2$

# 算子范数

定理

$\mathbf{C}^n$  上的任何向量范数  $\|\mathbf{x}\|$  均为  $\mathbf{x}$  的连续函数。

定理

已知  $\mathbf{C}^m$  和  $\mathbf{C}^n$  上的同类向量范数  $\|\cdot\|_V$ ,  $A_{m \times n}$

若定义

$$\|A\|_M = \max_{\mathbf{x} \neq 0} \frac{\|A\mathbf{x}\|_V}{\|\mathbf{x}\|_V} = \max_{\|\mathbf{x}\|_V=1} \|A\mathbf{x}\|_V \quad (1-25)$$

则  $\|A\|_M$  是一种矩阵范数, 且与已知的向量范数相容

我们称由关系式 (1-25) 定义的矩阵范数为从属向量范数的矩阵范数简称从属范数或算子范数。

算子范数  $\Rightarrow$  矩阵范数,  
反之不可!



1) 列范数:  $\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$  (列和范数)

2) 行范数:  $\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$  (行和范数)

3)  $F$ 范数:  $\|A\|_F = \sqrt{\sum_{i,j=1}^n a_{ij}^2}$

4) 2范数:  $\|A\|_2 = \sqrt{\lambda_{\max}}$  ,  $\lambda_{\max}$  是  $A^T A$  的最大特征值  
(谱范数)

**$F$ 范数,  $m1$ 范数都不是算子范数, 列和范数, 行和范数, 谱范数是算子范数。**

常用的有  $p=1, 2, \infty$ , 对应  $\|A\|_1, \|A\|_2, \|A\|_\infty$

显然有  $\|Ax\|_p \leq \|A\|_p \|x\|_p$

**推论** 对任何算子范数，单位矩阵  $I \in \mathbf{R}^{n \times n}$  的范数值为1，即

$$\|I\| = 1。$$

事实上，

$$\|I\| = \max_{x \neq 0} \frac{\|Ix\|}{\|x\|} = \max_{x \neq 0} \frac{\|x\|}{\|x\|} = 1$$

特别地， $\|A\|_{m_1}$ 、 $\|A\|_F$  不是算子范数。

事实上，

$$\|I\|_{m_1} = \sum_{i=1}^n \sum_{j=1}^n |a_{ij}| = \sum_{i=1}^n 1 = n \neq 1 \quad \|I\|_F = \sqrt{\sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2} = \sqrt{\sum_{i=1}^n 1^2} = \sqrt{n} \neq 1$$

## 例：证明范数不等式

若  $\|B\| < 1$ ,  $\|\cdot\|$  为算子范数  $\Rightarrow I + B$  可逆, 且

$$\|(I + B)^{-1}\| \leq \frac{1}{1 - \|B\|}$$

**证明：（反证法）假设  $I+B$  不可逆，易知对应齐次方程组  $(I + B)x = 0$  有非零解，设为  $\bar{x}$ ，有**

$$(I + B)\bar{x} = 0 \Rightarrow B\bar{x} = -\bar{x}$$

**两边取范数，并利用范数定义**

$$\|B\| \cdot \|\bar{x}\| \geq \|B\bar{x}\| = \|-\bar{x}\| = \|\bar{x}\|$$

$$\because \|\bar{x}\| \neq 0 \Rightarrow \|B\| \geq 1$$

**矛盾！故  $I+B$  可逆。**



$$\because (I + B)(I + B)^{-1} = I$$

$$\Rightarrow (I + B)^{-1} = I - B(I + B)^{-1}$$

**两边取范数，并利用算子范数定义**

$$\begin{aligned} \|(I + B)^{-1}\| &\leq \|I\| + \|B(I + B)^{-1}\| \\ &\leq 1 + \|B\| \|(I + B)^{-1}\| \end{aligned}$$

$$\therefore \|(I + B)^{-1}\| \leq \frac{1}{1 - \|B\|}$$



可以证明：

- 1.任意给定的矩阵范数必然存在与之相容的向量范数；  
任意给定的向量范数必然存在与之相容的矩阵范数（如从属范数）。
2. 一个矩阵范数可以与多种向量范数相容（矩阵的 $m_1$ -范数与向量的 $p$ -范数相容）；多种矩阵范数可以与一个向量范数相容（矩阵的 $F$ -范数、2-范数与向量的2-范数相容）。
3. 从属范数一定与所定义的向量范数相容，但是矩阵范数与向量范数相容却未必有从属关系。（矩阵的 $F$ -范数与向量的2-相容，但无从属关系）。
4. 并非任意的矩阵范数与任意的向量范数相容。

矩阵范数与向量范数不相容的例子：

取  $A = \begin{pmatrix} 1 & 1 \\ 0 & 0 \end{pmatrix}$ ,  $x = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ , 则有  $\|A\|_1 = 1$ ,  $\|x\|_\infty = 1$ ,

而  $\|Ax\|_\infty = 2 > \|A\|_1 \cdot \|x\|_\infty$


故矩阵的  $\|\cdot\|_1$  与向量的  $\|\cdot\|_\infty$  不相容。

# 谱半径及其与范数的关系

矩阵 $A$ 的谱半径:  $\rho(A) = \max_{1 \leq k \leq n} |\lambda_k|$

$\lambda_k$ 是复数时,  $|\lambda_k|$ 是复数模;

$A \in R^{n \times n}$ ,  $\lambda_k, k = 1, 2, \dots, n$ 是 $A$ 的 $n$ 个特征值。



当 $A$ 为对称矩阵时, 有

$$\rho(A) = \|A\|_2$$

事实上, 当 $A$ 为对称矩阵时, 即当  $A = A^T$  时,  
由矩阵2-范数的定义, 得

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)} = \sqrt{\lambda_{\max}(A^2)} = |\lambda_{\max}(A)| = \rho(A)$$

### 定理3.3

$\rho(A) \leq \|A\|$ ,  $\|\cdot\|$  是任意的矩阵算子范数。

### 证明

设  $\lambda_k$  是  $A$  的任意特征值,  $x^{(k)}$  是对应的特征向量, 则有

$$Ax^{(k)} = \lambda_k x^{(k)}$$

两边取算子范数有

$$\|A\| \|x^{(k)}\| \geq \|Ax^{(k)}\| = \|\lambda_k x^{(k)}\| = |\lambda_k| \|x^{(k)}\|$$

$$\because \|x^{(k)}\| \neq 0, \text{同除 } \|x^{(k)}\|, \text{ 有 } \|A\| \geq |\lambda_k|$$

由  $\lambda_k$  的任意性, 有  $\|A\| \geq \max |\lambda_k| = \rho(A)$





问实值函数  $\rho(A)$  可不可以作为  $A$  的一种范数？

取  $A = B^T = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}$ ，则有  $\rho(A) = 0$ ， $\rho(B) = 0$ ，而

$\rho(A + B) = 1$ ，即有  $\rho(A) + \rho(B) = 0$ ；从而

$$\rho(A + B) > \rho(A) + \rho(B) = 0$$

故不可以作为  $A$  的一种范数。

## 四、迭代法的收敛条件与误差估计

### 1、收敛条件

定理：  $x^{(k+1)} = B x^{(k)} + g$  对任意  $x^{(0)}$  都收敛  $\Leftrightarrow \rho(B) < 1$

引理：  $\lim_{k \rightarrow \infty} A^k = 0 \Leftrightarrow \rho(A) < 1$

#### 定理证明：必要性

设  $\lim_{k \rightarrow \infty} x^{(k)} = x^*$ ，在迭代式  $x^{(k+1)} = B x^{(k)} + g$  令  $k \rightarrow \infty$ ，有

$$x^* = B x^* + g$$

$$\text{于是有： } x^{(k)} - x^* = (B x^{(k-1)} + g) - (B x^* + g)$$

$$= B(x^{(k-1)} - x^*) = B^2(x^{(k-2)} - x^*) = \cdots = B^k(x^{(0)} - x^*)$$

由  $\lim_{k \rightarrow \infty} x^{(k)} = x^*$  及  $x^{(0)}$  和  $x^*$  的任意性，有  $\lim_{k \rightarrow \infty} B^k = 0$

在由引理，得出  $\rho(B) < 1$ ;



$$x^{(k+1)} = B x^{(k)} + g \quad \Downarrow \Leftrightarrow \rho(B) < 1$$

## 定理证明：充分性

$\because \rho(B) < 1 \Rightarrow I - B$  非奇异  $\Rightarrow$  线性方程组  $(I - B)x = g$  有唯一解  $x^*$

$$\text{于是有 } (I - B)x^* = g \Rightarrow x^* = Bx^* + g$$

$$\begin{aligned} \text{因此有: } x^{(k)} - x^* &= (Bx^{(k-1)} + g) - (Bx^* + g) \\ &= B(x^{(k-1)} - x^*) = B^2(x^{(k-2)} - x^*) = \cdots = B^k(x^{(0)} - x^*) \end{aligned}$$

$$\because \rho(B) < 1 \Rightarrow \lim_{k \rightarrow \infty} B^k = 0$$

取极限，利用引理，得出  $\lim_{k \rightarrow \infty} x^{(k)} = x^*$



## 2、收敛的判别条件（充分条件）

定理：  $x^{(k+1)} = B x^{(k)} + g \iff \rho(B) < 1$

### 判别条件I

若  $\|B\| < 1 \Rightarrow \forall x^{(0)} \in R^n,$

$$x^{(k+1)} = B x^{(k)} + g$$

都收敛其不动点  $x^*$ , 这里  $\|B\|$  是  $B$  的某种算子范数。

证明要点： $\because \rho(B) \leq \|B\| < 1$ , 由定理得。

注意，该条件是充分条件，且范数有一个即可。



## 判别条件II

若A为严格对角占优矩阵，则线性方程组 $Ax=b$ 的Jacobi和Seidel迭代对任何 $x^{(0)}$ 都收敛。（证明见书）

\*严格行对角占优矩阵 $(a_{ij})_{n \times n}$ 满足：

$$|a_{kk}| > \sum_{\substack{j=1 \\ j \neq k}}^n |a_{kj}|, \forall k$$

$$\begin{pmatrix} 6 & -1 & 5 \\ 3 & -5 & 1 \\ 2 & 3 & 7 \end{pmatrix} ?$$

\*严格列对角占优矩阵 $(a_{ij})_{n \times n}$ 满足：

$$|a_{kk}| > \sum_{\substack{i=1 \\ i \neq k}}^n |a_{ik}|, \forall k$$

严格行和严格列对角占优矩阵统称严格对角占优矩阵！

定理：严格对角占优矩阵是奇异的。（证明见书）



## 判别条件III

若  $A$  为正定矩阵，则线性方程组  $Ax = b$  的 Seidel 迭代对任何  $x^{(0)}$  都收敛。

正定矩阵：  $A$  的  $k$  阶主子式  $\Delta_k > 0, k = 1, 2, \dots, n$

$$\because 6 > 0, \begin{vmatrix} 6 & -1 \\ 3 & 5 \end{vmatrix} > 0, \begin{vmatrix} 6 & -1 & 5 \\ 3 & 5 & 1 \\ 0 & 0 & 7 \end{vmatrix} > 0$$

$$\therefore \begin{pmatrix} 6 & -1 & 5 \\ 3 & 5 & 1 \\ 0 & 0 & 7 \end{pmatrix} \text{是正定矩阵!}$$



## 定理3.7

**Sor**法收敛的必要条件是松弛因子 $\omega$ 满足 $0 < \omega < 2$

**证明**  $\because$  Sor法的迭代矩阵为

$$B_{\omega} = (D - \omega L)^{-1} [(1 - \omega)D + \omega U]$$

$$\therefore \det B_{\omega} = \det (D - \omega L)^{-1} \cdot \det [(1 - \omega)D + \omega U]$$

$$= \det D^{-1} \cdot \det (1 - \omega)D = (1 - \omega)^n$$

设 $\lambda_k, k = 1, 2, \dots, n$ 是 $B_{\omega}$ 的 $n$ 个特征值

$$\Rightarrow \det B_{\omega} = \lambda_1 \lambda_2 \cdots \lambda_n = (1 - \omega)^n$$

$$\text{收敛} \Leftrightarrow \rho(B_{\omega}) < 1$$

$$\text{由} (1 - \omega)^n = \lambda_1 \lambda_2 \cdots \lambda_n \leq [\rho(B_{\omega})]^n < 1 \Rightarrow 0 < \omega < 2$$



## 2、误差估计

**定理3.8** 设矩阵B的某种矩阵范数  $\|B\| < 1$ , 则有

$$1、\left\|x^{(k)} - x^*\right\| \leq \frac{\|B\|}{1 - \|B\|} \left\|x^{(k)} - x^{(k-1)}\right\|$$

$$2、\left\|x^{(k)} - x^*\right\| \leq \frac{\|B\|^k}{1 - \|B\|} \left\|x^{(1)} - x^{(0)}\right\|$$

**证明参照非线性方程求根定理的证明，  
将：绝对值换成范数、函数换成矩阵，注意范数关系的  
使用，**





### 例3.1 用Jacobi 迭代法解线性方程组

$$\begin{cases} 5x_1 + 2x_2 + 3x_3 = -12 \\ x_1 + 4x_2 + 2x_3 = 20 \\ 2x_1 - 3x_2 + 10x_3 = 3 \end{cases}$$

解

$$\therefore \text{Jacobi迭代格式为:} \begin{cases} x_1^{(k+1)} = -2.4 - 0.4x_2^{(k)} - 0.6x_3^{(k)} \\ x_2^{(k+1)} = 5 + 0.25x_1^{(k)} - 0.5x_3^{(k)} \\ x_3^{(k+1)} = 0.3 - 0.2x_1^{(k)} + 0.3x_2^{(k)} \end{cases}$$

$$\therefore \text{Jacobi迭代矩阵 } B_J = \begin{bmatrix} 0 & -0.4 & -0.6 \\ 0.25 & 0 & -0.5 \\ -0.2 & 0.3 & 0 \end{bmatrix}$$

$$\therefore \|B_J\|_F = 0.981071 < 1$$

**Jacobi迭代收敛!**



取 $x^{(0)} = (0, 0, 0)^T$  计算

$$x^{(1)} = (-2.4, 5, 0.3)^T, \quad \|x^{(1)} - x^{(0)}\|_{\infty} = 5 > 10^{-4},$$

$$x^{(2)} = (-4.58, 4.25, 2.28)^T, \quad \|x^{(2)} - x^{(1)}\|_{\infty} = 2.06 > 10^{-4}$$

$\vdots$

$$x^{(18)} = (-4., 2.99997, 2.)^T, \quad \|x^{(18)} - x^{(17)}\|_{\infty} = 0.41 \cdots \times 10^{-4} < 10^{-4}$$

**故所求近似解为**

$$x_1 = -4, x_2 = 2.9997, x_3 = 2$$

**准确解:**

$$x_1 = -4, x_2 = 3, x_3 = 2$$



**例3.2：** 已知方程组

$$\begin{pmatrix} 1 & 2 & -2 \\ 1 & 1 & 1 \\ 2 & 2 & 1 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$$

**1、写出Jacobi和Seidel迭代格式；**

**2、判别两种迭代格式的收敛性。**

**解： 1、**

*Jacobi*迭代格式：
$$\begin{cases} x^{(k+1)} = -2y^{(k)} + 2z^{(k)} + 1 \\ y^{(k+1)} = -x^{(k)} - z^{(k)} + 2 \\ z^{(k+1)} = -2x^{(k)} - 2y^{(k)} + 3 \end{cases}$$

*Seidel*迭代格式：
$$\begin{cases} x^{(k+1)} = -2y^{(k)} + 2z^{(k)} + 1 \\ y^{(k+1)} = -x^{(k+1)} - z^{(k)} + 2 \\ z^{(k+1)} = -2x^{(k+1)} - 2y^{(k+1)} + 3 \end{cases}$$



**2、**

$$\because \det(\lambda I - B_J) = \begin{vmatrix} \lambda & 2 & -2 \\ 1 & \lambda & 1 \\ 2 & 2 & \lambda \end{vmatrix} = \lambda^3 = 0$$

**得特征值**  $\lambda_1 = \lambda_2 = \lambda_3 = 0 \Rightarrow \rho(B_J) = 0 < 1$ , *Jacobi*迭代收敛;

对*Seidel*迭代, 其对应的特征方程为

$$\det(\lambda(D - L) - U) = \begin{vmatrix} \lambda & 2 & -2 \\ \lambda & \lambda & 1 \\ 2\lambda & 2\lambda & \lambda \end{vmatrix} = \lambda(\lambda - 2)^2 = 0$$

**得特征值**  $\lambda_1 = 0, \lambda_2 = \lambda_3 = 2 \Rightarrow \rho(B_J) = 2 > 1$

*Seidel*迭代发散。

