

# 機械学習 第3回 識別（1）

立命館大学 情報理工学部

村上 陽平

Beyond Borders

1

## 講義スケジュール

□ 担当教員 1：村上、福森（第1回～第15回）

1	機械学習とは、機械学習の分類
2	機械学習の基本的な手順
3	<b>識別（1）</b>
4	識別（2）
5	識別（3）
6	回帰
7	サポートベクトルマシン
8	ニューラルネットワーク

9	深層学習
10	アンサンブル学習
11	モデル推定
12	パターンマイニング
13	系列データの識別
14	強化学習
15	半教師あり学習

□ 担当教員 2：叶昕辰先生（第16回の講義を担当）

2

# 今回の講義内容

- 取り扱う問題の定義
- 決定木の学習
  - ID3アルゴリズム
- 最近傍決定則
  - 特徴空間
  - 特徴ベクトル
  - プロトタイプ
  - パーセプトロンの学習規則
- 演習問題

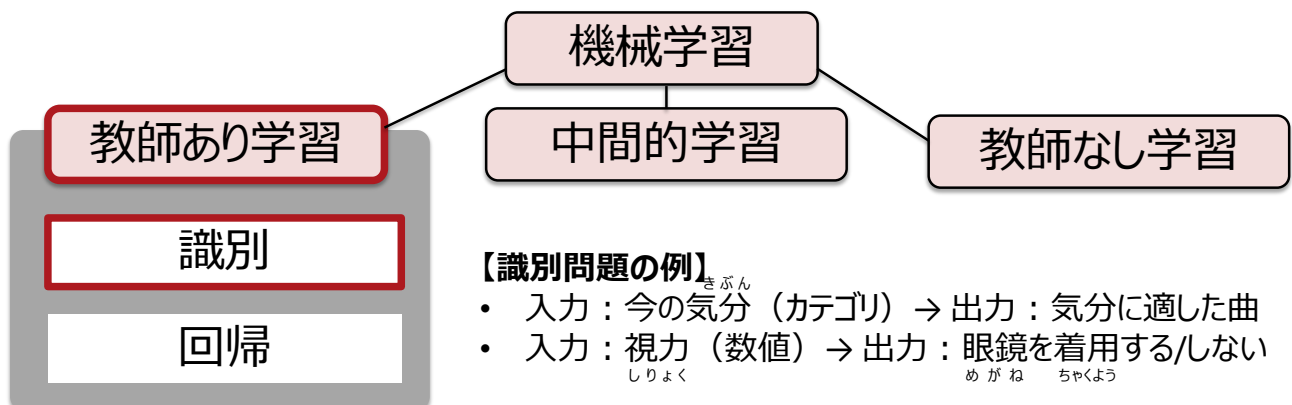
3

## 取り扱う問題の定義：教師あり・識別問題

- カテゴリデータ、または数値データからなる特徴ベクトルを入力して、それをクラス分けする識別器を作る

※ 教師あり学習の識別問題での学習データは、以下のペアで構成される

入力データの特徴ベクトル  $\leftarrow \{x_i, y_i\}$ ,  $i = 1, 2, \dots, N$   $\longrightarrow$  学習データの総数  
(カテゴリデータ/数値データ)  $\xrightarrow{\text{カテゴリ形式の正解情報}} \text{「クラス」と呼ぶ}$



4

# 決定木

## □ 概念学習

- 個々の事例から、あるクラスについて共通点をみつける学習手法
- その学習手法の代表例が**決定木**

## □ 決定木

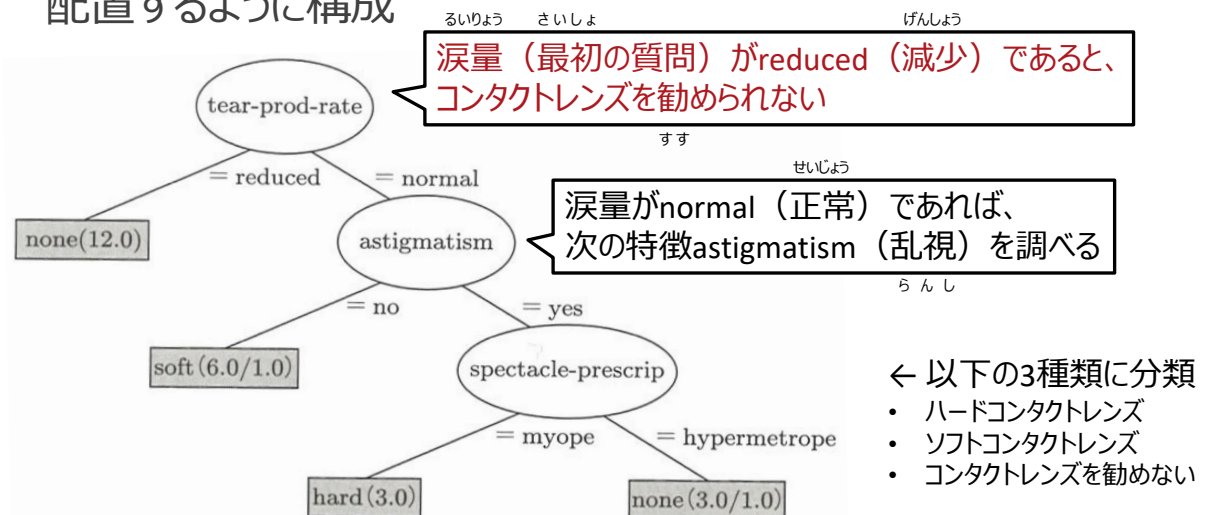
- データを分類する質問をノード(節)とし、  
分類結果をリーフ(葉)とする木構造の概念表現
  - ・ 根から分類結果が正である葉に至る節の分岐の値を **AND条件** で結合
  - ・ 全ての正の葉に関して、そのように得られた論理式を **OR条件** で結合
- 木構造は、人間の目から見て学習結果がわかりやすい

5

# 決定木の学習：決定木

## □ 決定木の例（コンタクトレンズデータの場合）

- 得られる情報が多い質問（特徴）を木の上方のノードに配置するように構成



※ リーフを表す四角形に書かれている数字：そのリーフに分類された事例数

※ スラッシュと数字が続いている場合は、リーフに書かれたクラスに当てはまらない事例数

6

# 決定木の学習：ID3アルゴリズム

□ 決定木を作成する基本的な手順が、

ID3 (Iterative Dichotomiser 3) アルゴリズム

1. 全ての特徴の中から、<sup>なか</sup>得られる情報が最も多そうな特徴を最初の質問として選択
  - 「得られる情報が最も多そうな特徴」  
= 「特徴集合の中で最も分類能力の高い特徴」
  - <sup>い</sup>言い換えると、<sup>か</sup>乱雑さが少なくなるように分類できる特徴
2. 1. の質問によって、学習データをいくつかの部分集合に分割
  - 同クラスのデータからなる部分集合は、それ以上の質問を続ける必要なし
  - 異なるクラスのデータが混在する部分集合は、得られる情報が多そうな質問を選んでデータをさらに分割

7

# 決定木の学習：ID3アルゴリズム

□ エントロピーを用いた

データ集合の乱雑さ（分類能力の高さ）の評価

$$E(D) = -P_+ \log_2 P_+ - P_- \log_2 P_-$$

※  $E(D)$  : エントロピー（データ集合  $D$  の乱雑さ）、 $P_+$  : 正例の割合、 $P_-$  : 負例の割合

■ エントロピー  $E(D)$  は、

$P_+ = 1$  または  $P_- = 1$  のとき <sup>さいしょう</sup>最小値 0、  
 $P_+ = P_- = 0.5$  のとき <sup>さいだい</sup>最大値 1 となる

■ エントロピーの値が <sup>さいはん</sup>小さいほど、集合が乱雑ではない

（同じクラスのものが大半を占めている）ということを示す

8

# 決定木の学習：ID3アルゴリズム

## □ 情報獲得量

- 特徴値に基づく分類によるエントロピーの減少量
- その特徴を選択することによって得られる情報の大きさ
- 情報獲得量が大きい特徴を選んでデータを分割する

### 情報獲得量

$$\text{Gain}(D, a) \equiv \underbrace{E(D)}_{\text{分類前のエントロピー}} - \underbrace{\sum_{v \in \text{Values}(a)} \frac{|D_v|}{|D|} E(D_v)}_{\text{分類後のエントロピー}}$$

分類前のエントロピー

分類後のエントロピー

- 分類後の集合数 = 特徴値の種類数
- 集合の要素数の割合で重み付け

※  $E(\cdot)$  : エントロピー、 $|\cdot|$  : 集合「 $\cdot$ 」の要素数、 $\text{Values}(a)$  : 特徴 $a$ のとりうる値  
 $D_v$  : 値 $v \in \text{Values}(a)$ をとる学習データの集合

9

## 決定木：例題（補足資料）

- 以下は、ある人がゴルフに参加するかを<sup>きしゅう</sup>気象条件を特徴として決定するデータである。

	天気	気温	湿度	風	ゴルフ
1	晴	高温	多湿	なし	不参加
2	晴	高温	多湿	あり	不参加
3	曇	高温	多湿	なし	参加
4	雨	適温	多湿	なし	参加
5	雨	低温	標準	なし	参加
6	雨	低温	標準	あり	不参加
7	曇	低温	標準	あり	参加
8	晴	適温	多湿	なし	不参加
9	晴	低温	標準	なし	参加
10	雨	適温	標準	なし	参加
11	晴	適温	標準	あり	参加
12	曇	適温	多湿	あり	参加
13	曇	高温	標準	なし	参加
14	雨	適温	多湿	あり	不参加

- このデータのエントロピー $E(D)$ を求めたい。
- 各特徴量の情報獲得量を計算して、最初のデータ分割に用いる特徴を見つけたい。

# 決定木：例題（補足資料）

## □ エントロピー $E(D)$

- 全14事例中、参加が9事例、不参加が5事例なので

$$E(D) = -\frac{9}{14}\log_2\frac{9}{14} - \frac{5}{14}\log_2\frac{5}{14} \doteq 0.94$$

## □ 情報獲得量

$$\text{Gain}(D, \text{天候}) = E(D) - \frac{5}{14}E(\text{晴}) - \frac{4}{14}E(\text{曇}) - \frac{5}{14}E(\text{雨})$$

$$\doteq 0.94 - 0.357 \times \left( -\frac{2}{5}\log_2\frac{2}{5} - \frac{3}{5}\log_2\frac{3}{5} \right)$$

$$- 0.286 \times \left( -\frac{4}{4}\log_2\frac{4}{4} - \frac{0}{4}\log_2\frac{0}{4} \right) - 0.357 \times \left( -\frac{3}{5}\log_2\frac{3}{5} - \frac{2}{5}\log_2\frac{2}{5} \right)$$

$$\doteq 0.247$$

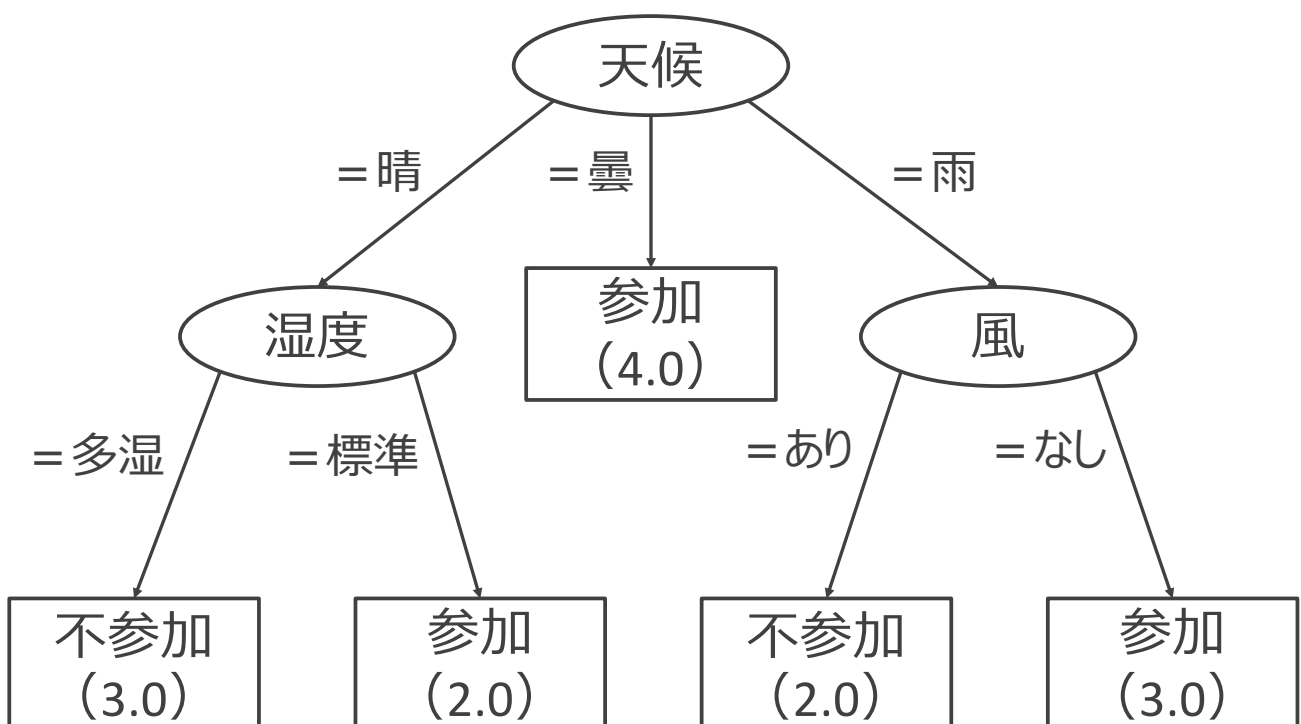
最も情報獲得量の多い特徴は「天候」  
この「天候」を特徴（質問）として  
データを分割すれば良い

同じ手順で、気温、湿度、風の情報獲得量を求めると、

$$\text{Gain}(D, \text{気温}) \doteq 0.029, \text{Gain}(D, \text{湿度}) \doteq 0.151, \text{Gain}(D, \text{風}) \doteq 0.048$$

12

# 決定木：例題（補足資料）



12

# 決定木の学習：ID3アルゴリズム

## □ 過学習

- モデルが学習データに特化しすぎたために、未知データに対して性能が下がる現象

## □ ID3アルゴリズムの過学習

- 一般的に小さい木を実現させることは難しい
- 全ての事例のエラーが無くなるように決定木を作成すると、その木が成長しすぎて、学習データに適応しすぎた過学習になりがち。
- 「適当なところで決定木の成長を止める方法」や「完全に学習させたあと、枝刈りする方法」で過学習に対処する必要がある。

10


# 最近傍決定則：特徴空間・特徴ベクトル

## □ 人間が顔画像から人物を識別することを考える

- 目だけを切り出した情報を用いて識別することは困難
- 髪型・顔の輪郭・肌の色などの複数の特徴も使うはず
  - ・ 機械学習では、このような複数の特徴をどのように表現するのか？

## □ 特徴空間・特徴ベクトル

- 特徴ベクトル  $\mathbf{x} = (x_1, x_2, \dots, x_d)^T$ 
  - ・  $d$ 個の特徴の並びを表現した  $d$ 次元ベクトル
- この  $d$ 次元空間を 特徴空間 と呼ぶ
- 特徴ベクトルは特徴空間上の1点を表す



特徴空間と特徴ベクトル

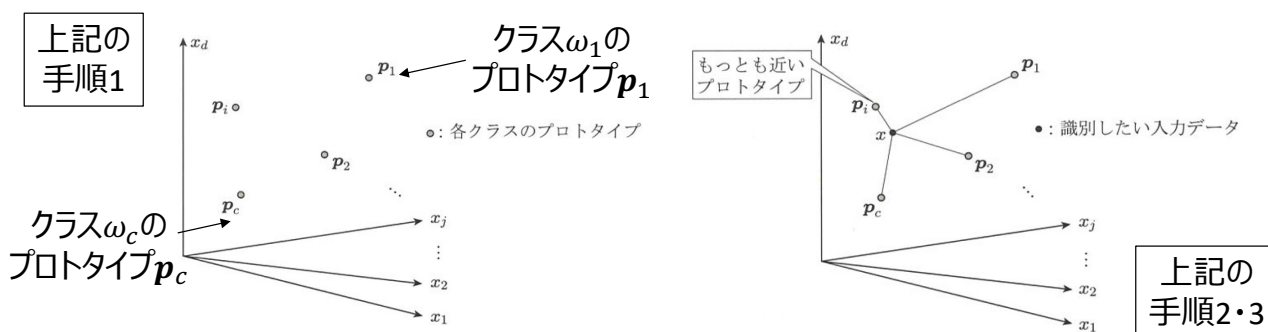
13

# 最近傍決定則

## □ 最近傍決定則（nearest neighbor法、NN法）

■ 入力特徴ベクトル $x$ が属するクラスを判定する簡単な方法

1. 各クラスにつき1つのプロトタイプ $p_i$ （代表となるベクトル）を用意  
• プロトタイプ： $p_1, p_2, \dots, p_c$ （※  $c$ ：クラスの総数）
2. 入力特徴ベクトルと各クラスのプロトタイプの距離を比較
3. 最も近いプロトタイプ $p_i$ の属するクラス $\omega_i$ を識別結果とする



14

## 最近傍決定則の定式化

□ 以下のようにクラス、特徴ベクトル、プロトタイプを定義

■  $c$ 個のクラス： $\omega_1, \omega_2, \dots, \omega_c$

■  $d$ 次元の入力特徴ベクトル： $x = (x_1, x_2, \dots, x_d)^T$

■ クラス $\omega_i$ のプロトタイプ： $p_i = (p_{i1}, p_{i2}, \dots, p_{id})^T$

□ 入力ベクトル $x$ とプロトタイプ $p_i$ のユークリッド距離

■ 
$$D(x, p_i) = \sqrt{(x_1 - p_{i1})^2 + (x_2 - p_{i2})^2 + \dots + (x_d - p_{id})^2}$$

□ 最も近いプロトタイプ $p_k$ が属するクラス $\omega_k$ の求め方


■ 
$$k = \arg \min_i D(x, p_i) \quad (i = 1, \dots, c)$$

15



# プロトタイプと識別面の関係

- 同じクラスに属する学習データは、特徴空間上で **クラスタ（かたまり）** になっていることが多い
- 例：2次元の特徴空間における2クラスの識別問題



2つのクラスを分離する **境界線（識別面）** をどのようにして決めるのか？


16

# プロトタイプと識別面の関係

- 最近傍決定則における識別面
  - 特徴ベクトル  $x$  がプロトタイプから等距離にある線
    - ・ つまり、**垂直二等分線**（※  $d$ 次元では垂直二等分  $d - 1$ 次元超平面）
  - プロトタイプの位置によって、正しい/間違っ**た**識別面が設定されることに注意

ちなみに...  
左図のように  
線形の識別面でクラスを  
分離できる場合を  
**線形分離可能**と呼ぶ

プロトタイプを結んだ線に対する垂直二等分線



正しく設定された識別面

間違っ**た**識別面

どうすれば、  
適切な識別面を  
求められるのか？

17


## 演習問題3-1（10分間）

- 以下の2つのクラスのプロトタイプが与えられたとき、  
入力  $x = (1,6)$  は最近傍決定則を用いると  
どちらのクラスに識別されるか？
  - クラス $\omega_1$ のプロトタイプ： $p_1 = (2,8)$
  - クラス $\omega_2$ のプロトタイプ： $p_2 = (8,4)$
- このときの識別面の式を求めよ。

18

## パーセプトロンの学習規則

- パーセプトロンの学習規則
  - 学習データから識別面を求めるアルゴリズムの1つ
  - 誤識別がなくなるように識別面を動かす（学習する）



19

# パーセプトロンの学習規則

## □ 識別関数の設定

- 入力ベクトル $\mathbf{x}$ とクラス $\omega_i$ のプロトタイプ $\mathbf{p}_i$ の距離

$$D(\mathbf{x}, \mathbf{p}_i) = \sqrt{(x_1 - p_{i1})^2 + (x_2 - p_{i2})^2 + \cdots + (x_d - p_{id})^2}$$
$$= \|\mathbf{x} - \mathbf{p}_i\| \quad \leftarrow \text{これを最小にする}\mathbf{p}_i\text{を求めるのが目的}$$

- 右辺を最小にする $\mathbf{p}_i$ は、右辺を2乗しても変わらないので

$$\|\mathbf{x} - \mathbf{p}_i\|^2 = \|\mathbf{x}\|^2 - 2\mathbf{p}_i^T \mathbf{x} + \|\mathbf{p}_i\|^2$$
$$= \|\mathbf{x}\|^2 - 2\left(\mathbf{p}_i^T \mathbf{x} - \frac{1}{2}\|\mathbf{p}_i\|^2\right)$$

$\mathbf{p}_i$ に関係なく  
常に同じ値なので無視する  
つね　　む　し

これを識別関数  $g_i(\mathbf{x})$  とする  
識別関数の値が大きいと、距離が小さくなる

20

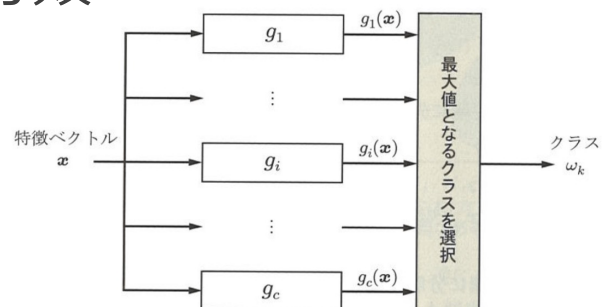
# パーセプトロンの学習規則

## □ 入力ベクトル $\mathbf{x}$ との距離が最小のプロトタイプ $\mathbf{p}_i$

- 識別関数  $g_1(\mathbf{x}), g_2(\mathbf{x}), \dots, g_c(\mathbf{x})$  の中から  
最大の $g_i(\mathbf{x})$ を求めれば良い

## □ 最近傍決定則によるクラス分類

- 特徴ベクトル $\mathbf{x}$ を入力し、  
各クラス $\omega_i$ に対応する  
識別関数 $g_i(\mathbf{x})$ を計算して、  
最大値をとるクラス $\omega_k$ を選択



最近傍決定則によるクラス分類

21

# パーセプトロンの学習規則

## □ 識別関数 $g_i(x)$

- 特徴ベクトルの各次元の値に対して係数をかけたものの和(第1項)を求め、それに定数(第2項)を足した形

$$g_i(x) = \mathbf{p}_i^T \mathbf{x} - \frac{1}{2} \|\mathbf{p}_i\|^2$$

- $x$ の係数と定数項を以下のように置き換える

- $x$ の係数 :  $p_{ij} = w_{ij}$  ( $j = 1, \dots, d$ )、定数項 :  $-\frac{1}{2} \|\mathbf{p}_i\|^2 = w_{i0}$

$$g_i(x) = w_{i0} + \sum_{j=1}^d w_{ij} x_j$$

- 「最近傍決定則におけるプロトタイプ的位置を調整する問題」が「識別関数の係数を調整する問題」に置き換わる

22

# パーセプトロンの学習規則

## □ 識別関数 $g_i(x)$ (つづき)


- 表記を簡単にするために、

$x_0 = 1$  とした  $d + 1$ 次元の特徴ベクトルを  $x$  とすると

$$g_i(x) = w_{i0} + \sum_{j=1}^d w_{ij} x_j = \sum_{j=0}^d w_{ij} x_j = (w_{i0}, \dots, w_{id})(x_0, \dots, x_d)^T = \mathbf{w}_i^T \mathbf{x}$$

※ 重みベクトル :  $\mathbf{w}_i = (w_{i0}, \dots, w_{id})^T$

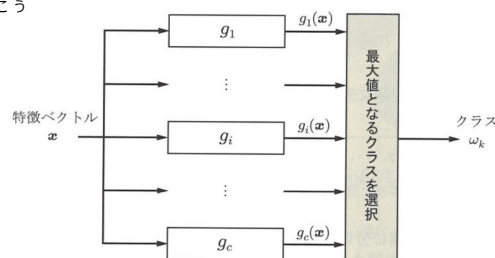
識別関数は入力の重み付き線形和



識別関数  $g_i(x)$  の計算メカニズム

「重み付き線形和」と「最大値選択」を組み合わせた計算機構をパーセプトロンと呼ぶ

きこう



【再掲】最近傍決定則によるクラス分類

23

# パーセプトロンの学習規則

## □ 識別関数の学習

- 線形分離可能な学習データに対して  
識別関数の重み $w_{ij}$ を正しく決定できれば  
最近傍決定則による誤りのない識別ができる。  
あやま
- $\chi_i$  ( $i = 1, \dots, c$ ) をクラス $\omega_i$ に属するデータ集合としたとき  
 $\chi_i$ に属する全ての $x$ に対して、以下の式が成り立つように  
重みを調整すれば良い。

$$g_i(x) > g_j(x) \quad (j = 1, \dots, c, j \neq i)$$

クラス $\omega_i$ に属する全てのデータ $x$ に対して  
クラス $\omega_i$ の識別関数の値  $g_i(x)$ が、他の識別関数の値  $g_j(x)$ を上回れば良い  
ほ か うわまわ

24

# パーセプトロンの学習規則

## □ ここから、2クラスの識別関数の学習を考える

- 2クラスの場合、入力に対する2つの識別関数の値の  
大小を比較した結果から識別結果が得られる  
だいしょう
- 2つの識別関数の差を、新たな識別関数 $g(x)$ とする  
あら

$$g(x) = g_1(x) - g_2(x)$$

$$= \mathbf{w}_1^T \mathbf{x} - \mathbf{w}_2^T \mathbf{x} = (\mathbf{w}_1^T - \mathbf{w}_2^T) \mathbf{x} = \mathbf{w}^T \mathbf{x}$$

識別関数 $g(x)$ の値の意味  $\left\{ \begin{array}{l} g(x) = \mathbf{w}^T \mathbf{x} > 0 \rightarrow x \text{ はクラス } \omega_1 \text{ に属する} \\ g(x) = \mathbf{w}^T \mathbf{x} = 0 \rightarrow x \text{ は識別面上にある} \\ g(x) = \mathbf{w}^T \mathbf{x} < 0 \rightarrow x \text{ はクラス } \omega_2 \text{ に属する} \end{array} \right.$

25

# パーセプトロンの学習規則

□ 以下を満たすように重み $w$ を調整する


$$\begin{cases} g(x) = w^T x > 0 & (x \in \chi_1) \\ g(x) = w^T x < 0 & (x \in \chi_2) \end{cases}$$

- 適当な重み（初期値）からはじめて、ある学習データに対して上式と異なる結果が出たとき重みを修正するアルゴリズムを考える
- ここまで特徴ベクトル $x$ が存在する特徴空間を考えてきたがここからは重みベクトル $w$ を要素とする重み空間を考える
  - 特徴空間が $d$ 次元ならば、重み空間は $d + 1$ 次元となる

26

# パーセプトロンの学習規則

□ 重み $w$ の修正方針



■  $w_{(0)}$ を重みの初期値とする

- 重み空間で超平面 $w^T x = 0$ を考える
  - 重み空間では、 $x$ が定数、 $w$ が変数である
  - 個々の学習データ $x$ に1つの超平面 $w^T x = 0$ が対応する
  - 超平面を境に $w^T x$ の正負が反転する

■ 誤識別が生じたときのみ重みを修正

- 例：クラス $\omega_1$ のデータ $x$ に対して  $g(x) = w_{(0)}^T x < 0$
- $w_{(0)}$ が超平面を超えるように重みを移動させる
- 超平面に垂直な方向へ移動させるのが最も近道

↓  
 **$w$ を $x$ の方向へ移動させれば良い**

※ 理由： $x$ は超平面 $w^T x = 0$ の法線ベクトルだから

りゆう


ほうせん

27

# パーセプトロンの学習規則

## □ 重み $w$ の修正方針（つづき）

- 別の学習データに対しても、その時点での重みで識別する
  - 誤識別が起これば、重みを修正するという手順を繰り返す
  - データが変われば、前のデータとは異なる超平面となる



28

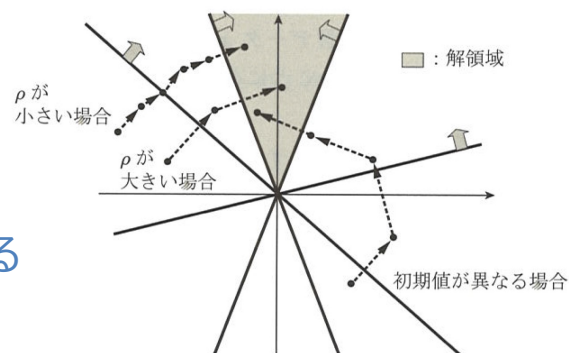
# パーセプトロンの学習規則

## □ 解領域

- 重み空間上で、全ての学習データに対して正しい識別結果を出力する領域
- 今回説明した手順は、**適当な初期値**から出発して、**修正を繰り返しながら解領域を探すプロセス**である

## □ 学習係数 $\rho$

- 重みの**修正幅**
  - 小さ過ぎると収束に時間がかかる
  - 大き過ぎると解領域付近で振動して収束しない可能性あり



解領域への重みの修正プロセス

29



# パーセプトロンの学習規則

## □ パーセプトロンの学習規則のアルゴリズム

1. 重みの初期値  $\mathbf{w} = \mathbf{w}_{(0)}$  を適当に決定する
2. 学習データの集合  $\chi$  から  $\mathbf{x}$  を1つ選び、識別関数の値  $g(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$  を計算する
3. 誤識別が起こったときのみ、以下の式に従い  $\mathbf{w}$  を修正する
  1.  $\mathbf{w}' = \mathbf{w} + \rho \mathbf{x}$  ( $\omega_1$  のデータを  $\omega_2$  と誤ったとき)
  2.  $\mathbf{w}' = \mathbf{w} - \rho \mathbf{x}$  ( $\omega_2$  のデータを  $\omega_1$  と誤ったとき)
4. 2. と 3. をすべての学習データについて繰り返す
5. 全て正しく識別できたら終了。そうでなければ、2. へ<sup>もど</sup>る

□ 学習データが線形分離可能ならば、この学習規則は有限回<sub>ゆうげんかい</sub>の繰り返しで終了する。

30

## 演習問題3-2（10分間）

- 前スライドのパーセプトロンの学習規則を用いて以下の表のデータから識別関数  $g(\mathbf{x})$  を求めよ。
- 重みの初期値 :  $w_0 = 0.2, w_1 = 0.3$
  - 学習係数 :  $\rho = 0.5$

クラス	$x$
$\omega_1$	1.0
$\omega_1$	0.5
$\omega_2$	-0.2
$\omega_2$	-1.3

31