

# 機械学習 第5回 識別 (3)

立命館大学 情報理工学部

福森 隆寛

Beyond Borders

# 講義担当者



**立命館  
19年目!**  
ねんめ

## □ 福森 隆寛 (ふくもり たかひろ)

■ 2015年3月 **立命館大学** 大学院情報理工学研究科  
博士課程後期課程 修了

■ 2015年4月 **立命館大学** 情報理工学部 助教

■ 2020年4月 **立命館大学** 情報理工学部 講師

大連理工大学の  
学生向けの  
講義を担当

■ 専門分野：音声・音響情報処理の研究

- 音声認識, 雑音抑圧, 叫び声検出など

私が現地（大連理工大学）で講義していた頃の写真



大連理工大学で授業 大連理工大学の食堂で昼食

休日観光@旅順&棒極島

# 講義スケジュール

(第1～4回、第14回) (第5～13回、第15回)

□ 担当教員：村上 陽平先生・福森 隆寛

1	機械学習とは、機械学習の分類
2	機械学習の基本的な手順
3	識別（１）
4	識別（２）
5	識別（３）
6	回帰
7	サポートベクトルマシン
8	ニューラルネットワーク

9	深層学習
10	アンサンブル学習
11	モデル推定
12	パターンマイニング
13	系列データの識別
14	強化学習
15	半教師あり学習

□ 担当教員：叶 昕辰先生（第16回の講義を担当）

# 今回の講義内容

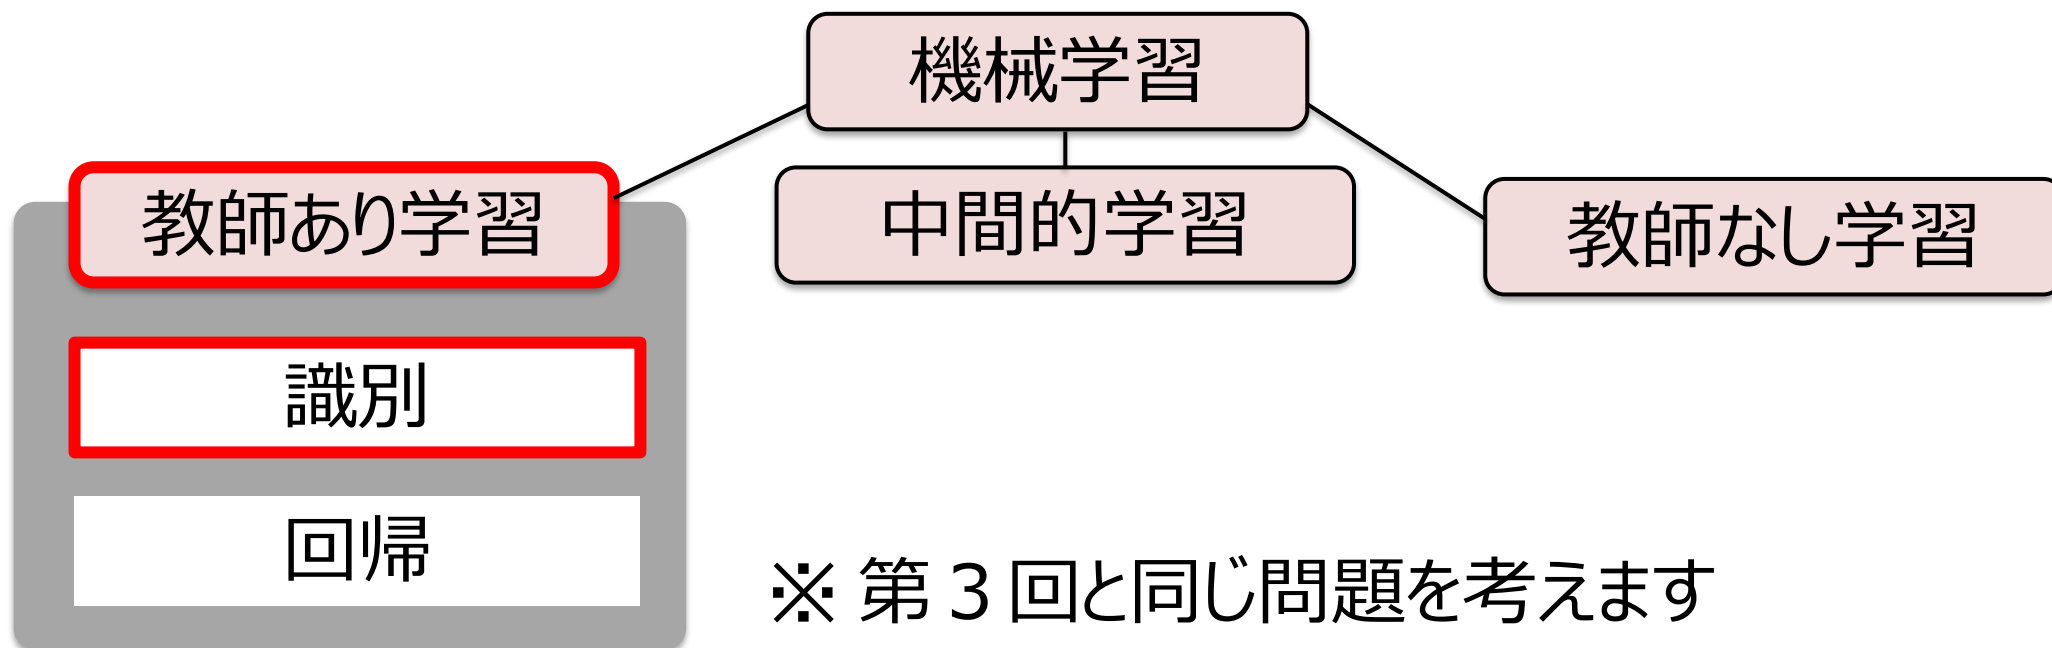
- 取り扱う問題の定義
- 統計的識別
- ベイズの定理<sup>て い り</sup>
- 最尤推定法<sup>さ い ゆ う</sup>
- ナイーブベイズ識別
- 演習問題

# 取り扱う問題の定義：教師あり・識別問題

- カテゴリデータ、または数値データからなる特徴ベクトルを入力して、それをクラス分けする識別器を作る

※ 教師あり学習の識別問題での学習データは、以下のペアで構成される

入力データの特徴ベクトル  $\leftarrow \{ \underline{x_i}, \underline{y_i} \}, \quad i = 1, 2, \dots, \underline{N} \longrightarrow$  学習データの総数  
(カテゴリデータ/数値データ) カテゴリ形式の正解情報  $\rightarrow$  「クラス」と呼ぶ



# 統計的識別

## □ 統計的識別

- 学習データの統計的性質に基づいてある入力が、あるクラスに分類される確率<sup>かくりつ</sup>を求めて、最も確率が高いクラスを出力する方法
- 統計的識別を理解する上で必要な確率の知識<sup>ちしき</sup>
  - 事前確率、事後確率<sup>じご</sup>
  - 最大事後確率則
  - 尤度<sup>ゆうど</sup>
  - 最尤推定法

# 統計的識別：事前確率

## □ 事前確率 (prior probability)

- 入力を観測する前に持っている、それぞれのクラスの  
起こりやすさ
- クラス数が $c$ である場合、  
クラス $\omega_i$ の事前確率は $P(\omega_i)$  ( $i = 1, \dots, c$ ) と表す

### ※ 補足： $P(A)$ と $p(x)$ の違い

- $P(A)$ ：離散的な事象 $A$ が起こる確率
- $p(x)$ ：連続値 $x$ に対して定義される確率密度関数

どちらも確率なので...

- $A$ が全事象の場合： $P(A) = 1$
- $p(x)$ を $x$ の全区間で積分すると1

# 統計的識別：事後確率、最大事後確率則

## □ 事後確率 (posterior probability)

- 入力 $\mathbf{x}$ が観測されたとき、結果がクラス $\omega_i$ である確率
- 条件付き確率  $P(\omega_i|\mathbf{x})$  で表現
  - 入力<sup>あと</sup>が観測された後で計算される確率

## □ 最大事後確率則

(maximum a posterior probability rule; MAP)

- 事後確率が最大となるクラスを識別結果とする手法
  - 統計的識別手法の代表的な方法
- 事後確率最大のクラス $C_{MAP}$ の算出式

$$C_{MAP} = \operatorname{argmax}_i P(\omega_i|\mathbf{x})$$



# 統計的識別：事後確率の求め方

## □ 事後確率を学習データから求める方法を考える

### ■ 条件付き確率 $P(\omega_i: \text{結論部} \mid \mathbf{x}: \text{条件部})$

- 条件部（特徴ベクトル $\mathbf{x}$ ）が一致<sup>いっち</sup>するデータを集めて、結論部（クラス $\omega_i$ ）の頻度を求めることで推定

### ■ 事後確率を<sup>ちよくせつ</sup>直接的に求めることは困難

- 基本的に特徴ベクトル $\mathbf{x}$ の組み合わせは膨大であり、それぞれの $\omega_i$ に対して全ての組み合わせの $\mathbf{x}$ を観測するのは困難
- 観測されない組み合わせが表れると条件付き確率を計算できない

### ■ 事後確率を間接的に求めることを考える

# 統計的識別：事後確率の求め方

□ **ベイズの定理**  $P(A|B) = \frac{P(B|A)P(A)}{P(B)}$  を用いても  
事後確率最大のクラスを計算できる

$$C_{MAP} = \operatorname{argmax}_i P(\omega_i | \mathbf{x}) = \operatorname{argmax}_i \frac{P(\mathbf{x} | \omega_i) P(\omega_i)}{P(\mathbf{x})}$$

ここで、 $P(\mathbf{x})$ はクラス番号 $i$ を変化させても一定なので、下式に置き換えられる

$$C_{MAP} = \operatorname{argmax}_i \frac{P(\mathbf{x} | \omega_i) P(\omega_i)}{\text{尤度 (likelihood)}}$$

**尤度** (likelihood)

クラス $\omega_i$ から特徴ベクトル $\mathbf{x}$ が出現する尤もらしさ

「**尤度と事前確率の積**」を最大とするクラスを求めることによって  
事後確率が最大となるクラスを間接的に計算できる

# 演習問題5-1（10分間）

□ 外見では区別のつかない箱Aと箱Bがある

■ 箱A：白玉が1個、黒玉が3個入っている

■ 箱B：白玉が4個、黒玉が1個入っている

1. 箱A、箱Bのいずれかから白玉を取り出す確率を求めよ。  
それぞれの箱の選び方は等確率とする。
2. 箱A、箱Bのいずれかから玉を取り出すと、白玉であった。  
この白玉が箱A、箱Bから取り出された確率をそれぞれ求めよ。  
それぞれの箱の選び方は等確率とする。
3. 箱A、箱Bの選ばれる確率が  $9 : 1$  であったとき、  
1. と 2. で求めた確率は、どのように変化するか？

# 学習データの生成確率

- 一般の問題では、事前確率や尤度はわからない
  - 事前確率や尤度を計算する確率モデルを仮定して、そのパラメータを学習データに合うように調整
  - それぞれのクラスは、特徴ベクトルを生成する何らかの確率分布をもっていて、学習データはその確率分布から、事例ごとに生成されたものと仮定
  - 学習データ全体 $D$ が生成される確率 $P(D)$ の算出式

$$P(D) = \prod_{i=1}^N P(\mathbf{x}_i)$$

- この式は、個々の事例 $\{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ の独立性を仮定している。

# 対数尤度

- $P(\cdot)$ は、何らかのパラメータ $\theta$ に基づいてデータの生成確率を計算するモデルなので  
下記のように $\theta$ を明示しながら $P(D)$ を書き直せる

$$P(D|\theta) = \prod_{i=1}^N P(x_i|\theta)$$

- 確率は1以下なので、全学習データの複数回の積は  
とても小さな数になるので、 $P(D|\theta)$ を対数化

たいすう  
**対数尤度** →  $\mathcal{L}(D) = \log P(D|\theta) = \sum_{i=1}^N \log P(x_i|\theta)$

対数尤度が高いほど、そのモデルから学習データが生成された確率が高い

# 最尤推定法

- **最尤推定法** (maximum likelihood estimation)
  - 対数尤度 $\mathcal{L}(D)$ が最大となるパラメータ $\theta$ を推定する手法
  - モデルパラメータが1次元 $\theta$ の場合、  
対数尤度 $\mathcal{L}(D)$ を最大にするパラメータ $\hat{\theta}$ は
$$\frac{d\mathcal{L}(D)}{d\theta} = 0$$
を満たす $\theta$ を計算する
  - パラメータが多次元でも考え方は同様
    - 各パラメータで $\mathcal{L}(D)$ を偏微分して極値を計算すれば良い

# 尤度の計算

## □ 事後確率最大則

$$C_{MAP} = \underset{i}{\operatorname{argmax}} P(\mathbf{x}|\omega_i)P(\omega_i)$$

の尤度 $P(\mathbf{x}|\omega_i)$ を求める方法を考える

## □ $P(\mathbf{x}|\omega_i) = P(x_1, \dots, x_d|\omega_i)$ を統計で求めるには

1. 学習データにあるクラス $\omega_i$ に属するデータを取り出す
2. そのデータに対して、**全ての特徴値の組み合わせの出現回数**を数える

- 学習データが小規模であるほど、統計が取れるほどのデータを揃えられる保証はない

# ナイーブベイズ識別

## □ 各特徴値が、他の特徴とは独立に決定すると仮定

- 特定の特徴について、特定の<sup>あた</sup>い値をとるデータを集めるので、すべての特徴値の組み合わせに対するデータよりは、かなり少ない量のデータで学習できる

## □ ナイーブベイズ識別法 (naive Bayes classifier)

- 上記の特徴の独立性を仮定した識別法
- 識別結果を $C_{NB}$ 、特徴値の種類数を $d$ とすると

$$C_{NB} = \operatorname{argmax}_i P(\omega_i) \prod_{j=1}^d P(x_j | \omega_i)$$

事後確率最大則の  
尤度 $P(x|\omega_i)$ が  
これに置き換わる



# ナイーブベイズ識別

$$C_{\text{NB}} = \operatorname{argmax}_i P(\omega_i) \prod_{j=1}^d P(x_j|\omega_i)$$

## □ $P(x_j|\omega_i)$ の算出方法

$$P(x_j|\omega_i) = \frac{n_j}{n_i} \quad \begin{array}{l} n_i : \text{学習データの中でクラス}\omega_i\text{に属するデータ数} \\ n_j : \text{クラス}\omega_i\text{のデータの中で、ある特徴が}x_j\text{をとるデータ数} \end{array}$$

## □ ゼロ頻度問題

- $n_j$ が0の場合、この特徴に対する尤度  $P(x_j|\omega_i)$  も0となり、この特徴を含む全ての事例の確率が0となる

### ■ **m推定**：ゼロ頻度問題の解決手段

- すでに  $m$  個の仮想的なデータがあり、それらによって各特徴値も出現している状況を設定する考え方

$$P(x_j|\omega_i) = \frac{n_j + mp}{n_i + m} \quad \begin{array}{l} m : \text{標本数} \\ p : \text{各特徴値の出現割合 } (p = 1/d \text{ が多い}) \end{array}$$

# ナイーブベイズ識別

## □ 数値特徴に対するナイーブベイズ識別

- カテゴリ特徴では、尤度が**離散事象**に対する確率分布  $P(x_j|\omega_i)$  であるのに対して、数値特徴では、数値に対する**確率密度関数**  $p(x_j|\omega_i)$  になる

$$C_{\text{NB}} = \operatorname{argmax}_i P(\omega_i) \prod_{j=1}^d P(x_j|\omega_i)$$

カテゴリ特徴に対するナイーブベイズ識別

$$C_{\text{NB}} = \operatorname{argmax}_i P(\omega_i) \prod_{j=1}^d p(x_j|\omega_i)$$

数値特徴に対するナイーブベイズ識別

**事前確率**  $P(\omega_i)$

学習データ中のクラス  $\omega_i$  に属するデータを数える最尤推定で計算する

**尤度**  $p(x_j|\omega_i)$  ※  $x_j$  が連続値なので、頻度を数える方法を利用できない  
尤度を計算する確率密度関数に適切な**統計モデル**を当てはめて  
そのモデルのパラメータを学習データから推定する


# 統計モデルの例

## □ 正規分布<sup>せいぎぶんぷ</sup>

- 数値データに対して多く用いられる統計モデル
- 釣り鐘型の分布<sup>つがねがた</sup>
- 正規分布のパラメータ：平均値  $\mu$ 、標準偏差  $\sigma$ 
  - これらのパラメータの値が定まると、分布の形状<sup>けいじょう</sup>が決まる

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\}$$

1次元データの正規分布



正規分布の形

※ 正規分布の平均値と標準偏差の最尤推定値 → 学習データの平均値と標準偏差

# 生成モデル・識別モデル

## □ 生成モデル

- 「あるクラス」の「ある特徴ベクトル」が「ある確率」に基づいて生成されるという考え方
- ベイズの定理を使って事後確率を考える

$$P(\omega_i | \mathbf{x}) = \frac{p(\mathbf{x} | \omega_i) P(\omega_i)}{p(\mathbf{x})}$$

$p(\mathbf{x} | \omega_i) P(\omega_i)$  : 生成モデルと解釈可能  
あるクラス $\omega_i$ が確率 $P(\omega_i)$ で選ばれ、そのクラスから特徴ベクトル $\mathbf{x}$ が確率 $p(\mathbf{x} | \omega_i)$ に基づいて生成

## □ 識別モデル

- $P(\omega_i | \mathbf{x})$ を直接推定する考え方
- 識別関数法（識別モデルに近い考え方）
  - 入力に対して正しい値（真値に近い値）を出力する関数を確率分布などの制約を一切考えずにデータだけに注目して構成

せいやく

いっさい

ちゅうもく

# 演習問題5-2（10分間）

- 以下の識別法は、生成モデルと識別モデルのどちらに分類されるか？理由も含めて答えよ。
  - ナイーブベイズ識別
  - パーセプトロンの学習規則に基づく識別関数