

# 機械学習 第5回 識別 (3)

立命館大学 情報理工学部

福森 隆寛

Beyond Borders

# 講義スケジュール

## □ 担当教員 1 : 福森 (第1回～第15回)

1	機械学習とは、機械学習の分類
2	機械学習の基本的な手順
3	識別 ( 1 )
4	識別 ( 2 )
5	<b>識別 ( 3 )</b>
6	回帰
7	サポートベクトルマシン
8	ニューラルネットワーク

9	深層学習
10	アンサンブル学習
11	モデル推定
12	パターンマイニング
13	系列データの識別
14	半教師あり学習
15	強化学習

## □ 担当教員 2 : 叶昕辰先生 (第16回の講義を担当)

# 今回の講義内容

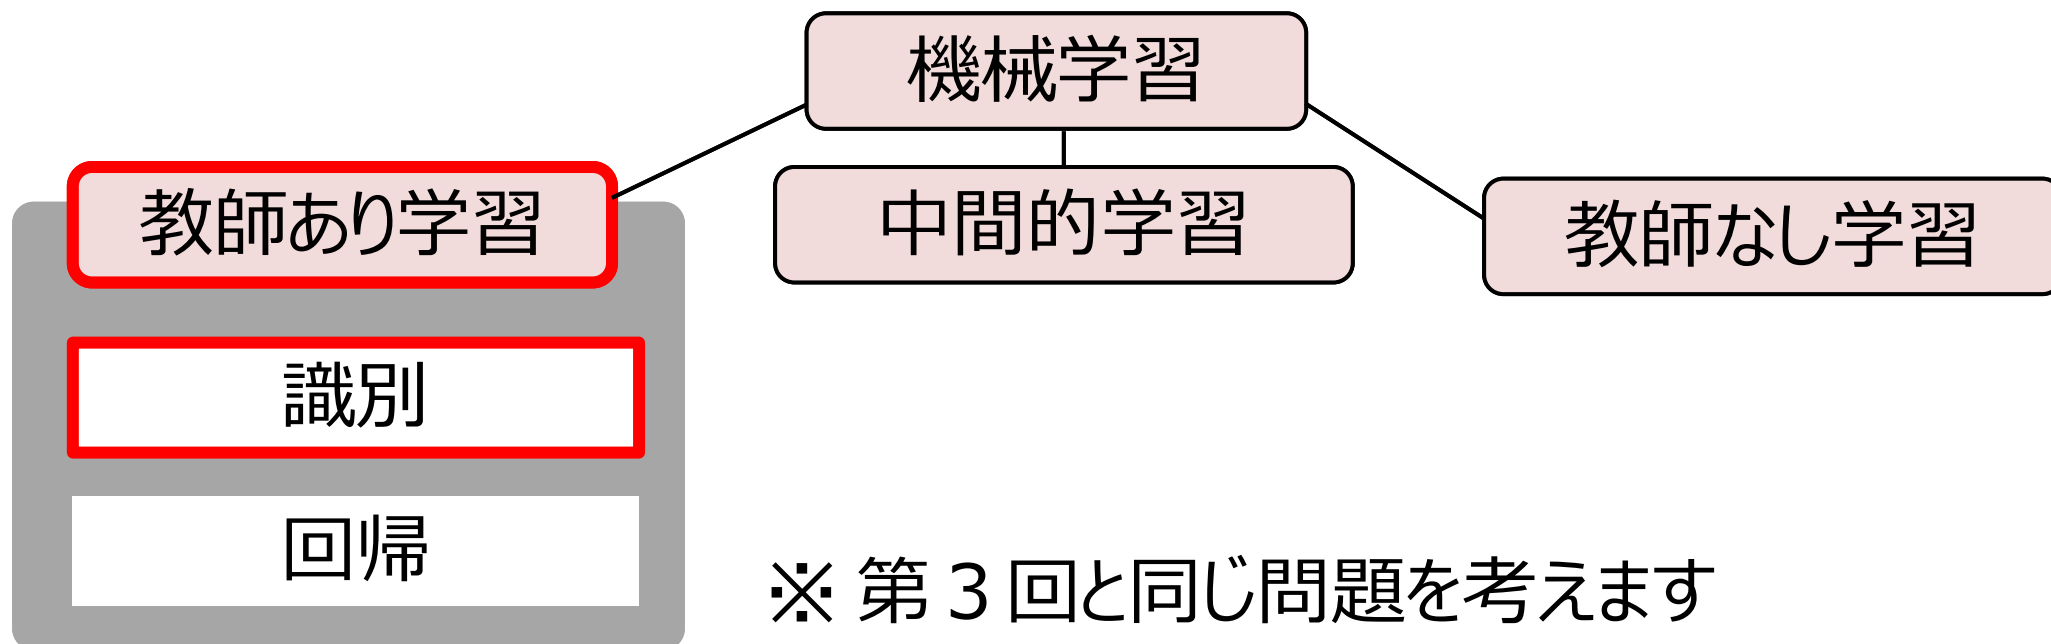
- 取り扱う問題の定義
- 統計的識別
- ベイズの定理<sup>て い り</sup>
- 最尤推定法<sup>さ い ゆ う</sup>
- ナイーブベイズ識別
- 演習問題

# 取り扱う問題の定義：教師あり・識別問題

- カテゴリデータ、または数値データからなる特徴ベクトルを入力して、それをクラス分けする識別器を作る

※ 教師あり学習の識別問題での学習データは、以下のペアで構成される

入力データの特徴ベクトル  $\leftarrow \{ \underline{x_i}, \underline{y_i} \}, \quad i = 1, 2, \dots, \underline{N} \longrightarrow$  学習データの総数  
(カテゴリデータ/数値データ)      カテゴリ形式の正解情報  $\rightarrow$  「クラス」と呼ぶ



# 統計的識別

## □ 統計的識別

- 学習データの統計的性質に基づいてある入力が、あるクラスに<sup>かくりつ</sup>分類される確率を求めて、最も確率が高いクラスを出力する方法
- 統計的識別を理解する上で必要な確率の<sup>ち し き</sup>知識
  - 事前確率、事後<sup>じご</sup>確率
  - 最大事後確率則
  - <sup>ゆうど</sup>尤度
  - 最尤推定法

# 統計的識別：事前確率

## □ 事前確率 (prior probability) 先验概率

- 入力を観測する前に持っている、それぞれのクラスの  
起こりやすさ
- クラス数が $c$ である場合、  
クラス $\omega_i$ の事前確率は $P(\omega_i)$  ( $i = 1, \dots, c$ ) と表す

※ 補足： $P(A)$ と $p(x)$ の違い 大写P：离散概率

- $P(A)$ ：离散的事象 $A$ が起こる確率
- $p(x)$ ：連続値 $x$ に対して定義される確率密度関数

小写p：概率密度函数

どちらも確率なので...

- $A$ が全事象の場合： $P(A) = 1$
- $p(x)$ を $x$ の全区間で積分すると1

# 統計的識別：事後確率、最大事後確率則

## □ 事後確率 (posterior probability) 后验概率

- 入力 $\mathbf{x}$ が観測されたとき、結果がクラス $\omega_i$ である確率
  - 条件付き確率  $P(\omega_i|\mathbf{x})$  で表現
    - 入力<sup>あと</sup>が観測された後で計算される確率
- 从  $\mathbf{x}$  分类为  $\omega_i$ .

## □ 最大事後確率則 将后验概率最大的类作为判别结果 (maximum a posterior probability rule; MAP)

- 事後確率が最大となるクラスを識別結果とする手法
  - 統計的識別手法の代表的な方法
- 事後確率最大のクラス $C_{MAP}$ の算出式

$$C_{MAP} = \underset{i}{\operatorname{argmax}} P(\omega_i|\mathbf{x})$$

# 統計的識別：事後確率の求め方

## □ 事後確率を学習データから求める方法を考える

### ■ 条件付き確率 $P(\omega_i: \text{結論部} \mid \mathbf{x}: \text{条件部})$

- 条件部（特徴ベクトル $\mathbf{x}$ ）が一致<sup>いっち</sup>するデータを集めて、結論部（クラス $\omega_i$ ）の頻度を求めることで推定

### ■ 事後確率を<sup>ちよくせつ</sup>直接的に求めることは困難

- 基本的に特徴ベクトル $\mathbf{x}$ の組み合わせは膨大であり、それぞれの $\omega_i$ に対して全ての組み合わせの $\mathbf{x}$ を観測するのは困難
- 観測されない組み合わせが表れると条件付き確率を計算できない

### ■ 事後確率を間接的に求めることを考える



# 統計的識別：事後確率の求め方

- **ベイズの定理**  $P(A|B) = \frac{P(B|A)P(A)}{P(B)}$  を用いても  
事後確率最大のクラスを計算できる

$$C_{MAP} = \operatorname{argmax}_i P(\omega_i | \mathbf{x}) = \operatorname{argmax}_i \frac{P(\mathbf{x} | \omega_i) P(\omega_i)}{P(\mathbf{x})}$$

ここで、 $P(\mathbf{x})$ はクラス番号 $i$ を変化させても一定なので、下式に置き換えられる

$$C_{MAP} = \operatorname{argmax}_i P(\mathbf{x} | \omega_i) P(\omega_i)$$

**尤度** (likelihood)

クラス $\omega_i$ から特徴ベクトル $\mathbf{x}$ が出現する尤もらしさ

## 間接算法

「**尤度と事前確率の積**」を最大とするクラスを求めることによって  
事後確率が最大となるクラスを間接的に計算できる

# 演習問題5-1 (10分間)

□ 外見では区別のつかない箱Aと箱Bがある

■ 箱A：白玉が1個、黒玉が3個入っている

■ 箱B：白玉が4個、黒玉が1個入っている

1. 箱A、箱Bのいずれかから白玉を取り出す確率を求めよ。  
それぞれの箱の選び方は等確率とする。21/40
2. 箱A、箱Bのいずれかから玉を取り出すと、白玉であった。  
この白玉が箱A、箱Bから取り出された確率をそれぞれ求めよ。  
それぞれの箱の選び方は等確率とする。A:5/21, B:16/21
3. 箱A、箱Bの選ばれる確率が 9 : 1 であったとき、  
1. と 2. で求めた確率は、どのように変化するか？  
61/200, A:45/61, B:16/61

# 学習データの生成確率

假设一个计算先验概率和似然的概率模型，调整参数以匹配训练数据

- 一般の問題では、事前確率や尤度はわからない
- 事前確率や尤度を計算する確率モデルを仮定して、そのパラメータを学習データに合うように調整
- それぞれのクラスは、特徴ベクトルを生成する何らかの確率分布をもっていて、学習データはその確率分布から、事例ごとに生成されたものと仮定
- 学習データ全体 $D$ が生成される確率 $P(D)$ の算出式

生成全体訓練  
数据的概率

$$P(D) = \prod_{i=1}^N P(\mathbf{x}_i)$$

- この式は、個々の事例 $\{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ の独立性を仮定している。

# 対数尤度

- $P(\cdot)$ は、何らかのパラメータ $\theta$ に基づいてデータの生成確率を計算するモデルなので  
下記のように $\theta$ を明示しながら $P(D)$ を書き直せる

数据是由参数为 $\theta$ 的

概率模型生成的，

故标注上 $\theta$

$$P(D|\theta) = \prod_{i=1}^N P(x_i|\theta)$$

- 確率は1以下なので、全学習データの複数回の積は  
とても小さな数になるので、 $P(D|\theta)$ を対数化

たいすう

対数尤度

$$\rightarrow \mathcal{L}(D) = \log P(D|\theta) = \sum_{i=1}^N \log P(x_i|\theta)$$

対数尤度が高いほど、そのモデルから学習データが生成された確率が高い

# 最尤推定法

极大似然估计

## □ 最尤推定法 (maximum likelihood estimation)

■ 対数尤度 $\mathcal{L}(D)$ が最大となるパラメータ $\theta$ を推定する手法

■ モデルパラメータが1次元 $\theta$ の場合、  
対数尤度 $\mathcal{L}(D)$ を最大にするパラメータ $\hat{\theta}$ は

$$\frac{d\mathcal{L}(D)}{d\theta} = 0$$

を満たす $\theta$ を計算する

■ パラメータが多次元でも考え方は同様

- 各パラメータで $\mathcal{L}(D)$ を偏微分して極値を計算すれば良い

# 尤度の計算

## □ 事後確率最大則

$$C_{MAP} = \operatorname{argmax}_i P(\mathbf{x}|\omega_i)P(\omega_i)$$

の尤度 $P(\mathbf{x}|\omega_i)$ を求める方法を考える

## □ $P(\mathbf{x}|\omega_i) = P(x_1, \dots, x_d|\omega_i)$ を統計で求めるには

1. 学習データにあるクラス $\omega_i$ に属するデータを取り出す
2. そのデータに対して、**全ての特徴値の組み合わせの出現回数**を数える

■ 学習データが小規模であるほど、  
統計が取れるほどのデータを揃えられる保証はない

# ナイーブベイズ識別

## □ 各特徴値が、他の特徴とは独立に決定すると仮定

- 特定の<sup>あた</sup>特徴について、特定の値をとるデータを集めるので、すべての特徴値の組み合わせに対するデータよりは、かなり少ない量のデータで学習できる

## □ ナイーブベイズ識別法 (朴素贝叶斯分类器 (naive Bayes classifier))

- 上記の特徴の独立性を仮定した識別法
- 識別結果を $C_{NB}$ 、特徴値の種類数を $d$ とすると

$$C_{NB} = \operatorname{argmax}_i P(\omega_i) \prod_{j=1}^d P(x_j | \omega_i)$$

事後確率最大則の  
尤度 $P(x|\omega_i)$ が  
これに置き換わる

# ナイーブベイズ識別

$$C_{\text{NB}} = \operatorname{argmax}_i P(\omega_i) \prod_{j=1}^d P(x_j | \omega_i)$$

## □ $P(x_j | \omega_i)$ の算出方法

$n_i$ :  $\omega_i$  類的数据数.

$$P(x_j | \omega_i) = \frac{n_j}{n_i}$$

$n_i$ : 学習データの中でクラス  $\omega_i$  に属するデータ数  
 $n_j$ : クラス  $\omega_i$  のデータの中で、ある特徴が  $x_j$  をとるデータ数

$n_j$ : 包含  $x_j$  的数据数.

## □ ゼロ頻度問題 零频问题

- $n_j$  が 0 の場合、この特徴に対する尤度  $P(x_j | \omega_i)$  も 0 となり、  
この特徴を含む全ての事例の確率が 0 となる

- **m推定**: ゼロ頻度問題の解決手段

解決方法

- すでに  $m$  個の仮想的なデータがあり、それらによって各特徴値も出現している状況を設定する考え方

$$P(x_j | \omega_i) = \frac{n_j + mp}{n_i + m}$$

$m$ : 標本数  
 $p$ : 各特徴値の出現割合 ( $p = 1/d$  が多い)



# ナイーブベイズ識別

## □ 数値特徴に対するナイーブベイズ識別

- カテゴリ特徴では、尤度が離散事象に対する確率分布  $P(x_j|\omega_i)$  であるのに対して、数値特徴では、数値に対する確率密度関数  $p(x_j|\omega_i)$  になる

$$C_{\text{NB}} = \operatorname{argmax}_i P(\omega_i) \prod_{j=1}^d \underbrace{P(x_j|\omega_i)}$$

カテゴリ特徴に対するナイーブベイズ識別

$$C_{\text{NB}} = \operatorname{argmax}_i P(\omega_i) \prod_{j=1}^d \underbrace{p(x_j|\omega_i)}$$

数値特徴に対するナイーブベイズ識別

**事前確率**  $P(\omega_i)$

学習データ中のクラス  $\omega_i$  に属するデータを数える最尤推定で計算する

**尤度**  $p(x_j|\omega_i)$  ※  $x_j$  が連続値なので、頻度を数える方法を利用できない  
尤度を計算する確率密度関数に適切な統計モデルを当てはめて  
そのモデルのパラメータを学習データから推定する

# 統計モデルの例


## □ <sup>せい き</sup>正規分布 正态分布

- 数値データに対して多く用いられる統計モデル
- <sup>つ がね が た</sup>釣り鐘型の分布
- 正規分布のパラメータ：平均値  $\mu$ 、標準偏差  $\sigma$ 
  - これらのパラメータの値が定まると、分布の形状が決まる

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\}$$

1次元データの正規分布

$$p(x) = \frac{1}{\sqrt{2\pi} \cdot \sigma} e^{\left( -\frac{(x - \mu)^2}{2\sigma^2} \right)}$$



正規分布の形

※ 正規分布の平均値と標準偏差の最尤推定値 → 学習データの平均値と標準偏差

# 生成モデル・識別モデル

## □ 生成モデル

- 「あるクラス」の「ある特徴ベクトル」が「ある確率」に基づいて生成されるという考え方
- ベイズの定理を使って事後確率を考える

$$P(\omega_i | \mathbf{x}) = \frac{p(\mathbf{x} | \omega_i) P(\omega_i)}{p(\mathbf{x})}$$

$p(\mathbf{x} | \omega_i) P(\omega_i)$  : 生成モデルと解釈可能  
あるクラス $\omega_i$ が確率 $P(\omega_i)$ で選ばれ、そのクラスから特徴ベクトル $\mathbf{x}$ が確率 $p(\mathbf{x} | \omega_i)$ に基づいて生成

## □ 識別モデル

- $P(\omega_i | \mathbf{x})$ を直接推定する考え方
- 識別関数法 (識別モデルに近い考え方)
  - 入力に対して正しい値 (真値に近い値) を出力する関数を確率分布などの制約を一切考えずにデータだけに注目して構成

# 演習問題5-2（10分間）

- 以下の識別法は、生成モデルと識別モデルのどちらに分類されるか？理由も含めて答えよ。
  - ナイーブベイズ識別 **生成モデル**
  - パーセプトロンの学習規則に基づく識別関数 **識別モデル**