

# 機械学習 第6回 回帰

立命館大学 情報理工学部

福森 隆寛

Beyond Borders

# 講義スケジュール

## □ 担当教員 1 : 福森 (第1回～第15回)

1	機械学習とは、機械学習の分類
2	機械学習の基本的な手順
3	識別 ( 1 )
4	識別 ( 2 )
5	識別 ( 3 )
6	<b>回帰</b>
7	サポートベクトルマシン
8	ニューラルネットワーク

9	深層学習
10	アンサンブル学習
11	モデル推定
12	パターンマイニング
13	系列データの識別
14	半教師あり学習
15	強化学習

## □ 担当教員 2 : 叶昕辰先生 (第16回の講義を担当)

# 今回の講義内容

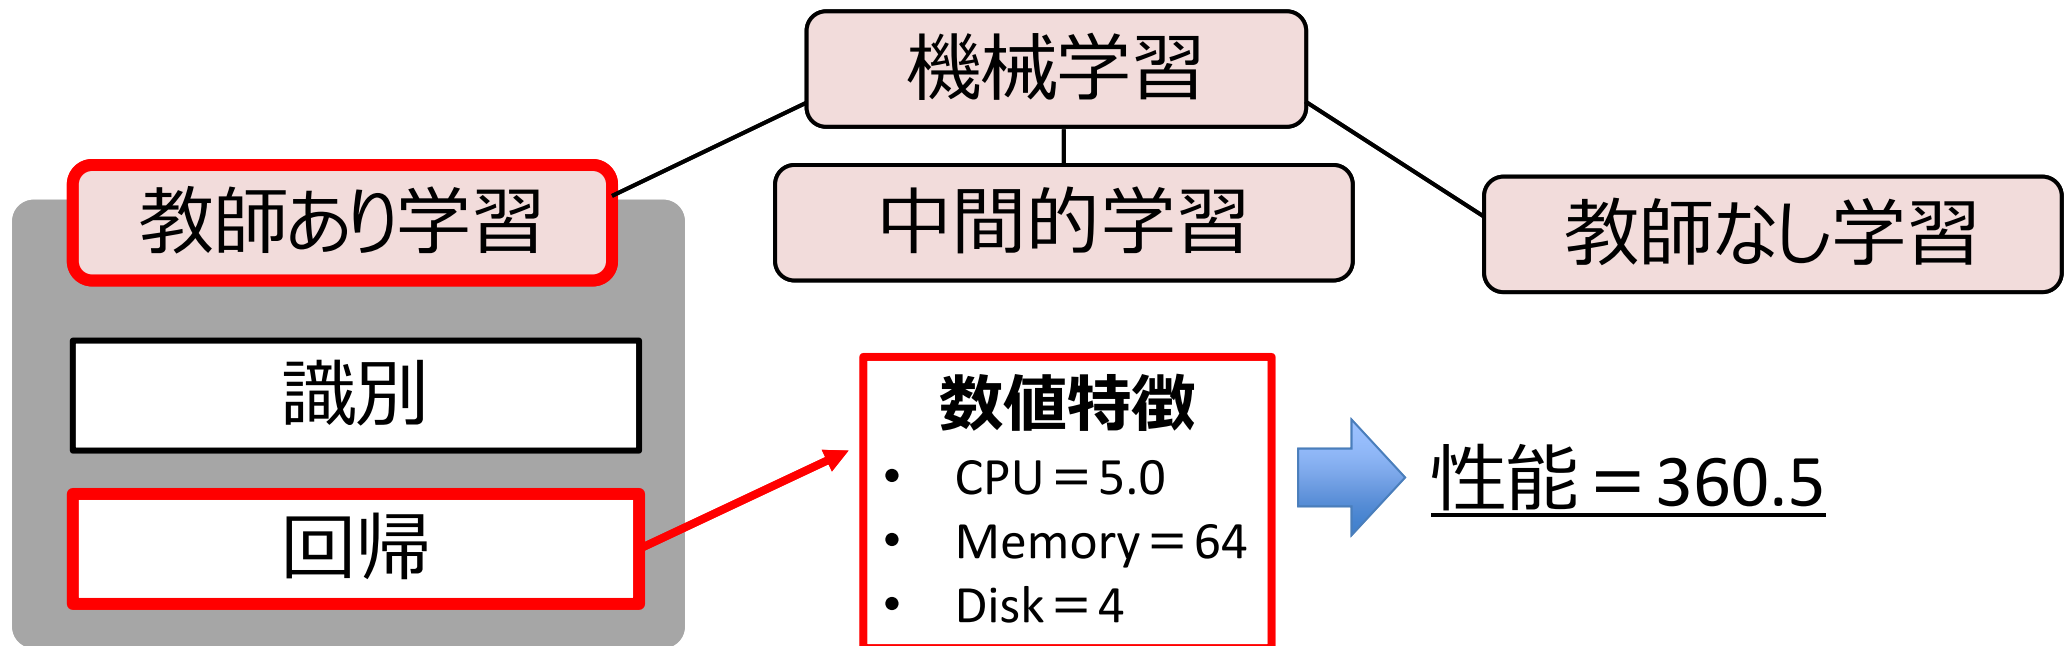
- 取り扱う問題の定義
- 線形回帰 最も単純な入力も出力もスカラーである場合の 回帰問題を考える
- 回帰モデルの評価 回帰式が未知データに対して正しく出力値を予測 するかを評価
- 正則化
- バイアスと分散のトレードオフ
- 回帰木 回帰木のリーフの値を線形回帰式とした木
- 演習問題

# 取り扱う問題の定義：教師あり・回帰

□ 数値データからなる特徴ベクトルを入力して、数値を出力する関数を作る

※ 教師あり学習の回帰問題での学習データは、以下のペアで構成される

入力データの特徴ベクトル  $\leftarrow \{\underline{x}_i, \underline{y}_i\}, \quad i = 1, 2, \dots, \underline{N} \longrightarrow$  学習データの総数  
(数値データ) 数値形式の正解情報  $\rightarrow$  「ターゲット」と呼ぶ




# 取り扱う問題の定義：教師あり・回帰

- 識別と回帰の境界は、それほど明確<sup>めいかく</sup>ではない
  - 識別：数値特徴を入力としてクラスを出力
  - 回帰：数値特徴を入力として数値を出力
  
- クラスによって異なる値をとるクラス変数を導入し<sup>どうにゆう</sup>  
入力からクラス変数の値を予測する問題を考えると  
識別問題を回帰問題として考えることもできる

# 線形回帰


输入输出都是标量

- 最も単純な入力も出力もスカラーである場合の回帰問題を考える
- 学習データから入力 $x$ を出力 $y$ に写像する関数 $\hat{c}(x)$ を推定



入力 $x$ が大きくなると  
出力 $y$ も大きい値になる  
傾向がみられる

この傾向を直線で表して  
入力 $x$ と出力 $y$ を関係づける



最小二乗法と同様の方法で  
なるべく誤差の少ない直線を求める

# 線形回帰

## □ 最小二乗法から回帰式を求める

■ 回帰式を  $\hat{c}(x) = w_1x + w_0$  とする

■ 誤差の二乗和は

$$E(\mathbf{w}) = \sum_{i=1}^N \{y_i - \hat{c}(x_i)\}^2 = (\mathbf{y} - \mathbf{X}\mathbf{w})^T (\mathbf{y} - \mathbf{X}\mathbf{w})$$

•  $\mathbf{X}$  : 1列目の全要素が1、2列目*i*行の要素が $x_i$ のパターン行列

•  $\mathbf{w}$  : 重みベクトル ※  $\mathbf{w} = (w_0, w_1)^T$

■  $\mathbf{w}$ で微分したものを0とすると、線形回帰式の重みは下式で計算できる

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

■ 入力 $x$ が*d*次元の場合も、同様の方法で計算できる

# 回帰モデルの評価

□ 回帰式が未知データに対して正しく出力値を予測するかを評価

□ 評価指標

R ■ 相関係数 : 正解と予測が、どの程度似ているのか

R<sup>2</sup> ■ 決定係数

- 「正解との離れ具合」と「平均との離れ具合」の比を1から引く
- $\tilde{y}$  :  $y_i$ の平均値

$$R^2 = 1 - \frac{\sum_{i=1}^N \{y_i - \hat{c}(x_i)\}^2}{\sum_{i=1}^N (y_i - \tilde{y})^2}$$

へんけい  
式変形により相関係数の二乗と一致するので $R^2$ と表記する



# 演習問題6-1（10分間）

□ 右表のような身長と体重のデータが与えられた

□ 身長 $x$ から体重 $\hat{c}(x)$ を予測する線形回帰式が

$$\hat{c}(x) = 0.625x - 48.604$$

であるときの決定係数と相関係数を計算せよ

身長と体重データ

番号	身長 [cm]	体重 [kg]
1	147.9	41.7
2	163.5	60.2
3	159.8	47.0
4	155.1	53.2
5	163.3	48.3
6	158.7	55.2
7	172.0	58.5
8	161.2	49.0
9	153.9	46.7
10	161.6	52.5

# 演習問題6-1（10分間） 解答例

番号	身長 $x_i$	体重 $y_i$	$\hat{c}(x)$	$(y_i - \hat{c}(x_i))^2$	$(y_i - \tilde{y})^2$
1	147.9	41.7	43.8	4.6	90.8
2	163.5	60.2	53.6	43.8	80.5
3	159.8	47.0	51.3	18.2	17.9
4	155.1	53.2	48.3	23.7	3.9
5	163.3	48.3	53.5	26.6	8.6
6	158.7	55.2	50.6	21.3	15.8
7	172.0	58.5	58.9	0.2	52.9
8	161.2	49.0	52.1	9.9	5.0
9	153.9	46.7	47.6	0.8	20.5
10	161.6	52.5	52.4	0.0	1.6

平均体重  $\tilde{y} \cong 51.2$

合計：149.0    合計：297.4

決定係数

$$R^2 = 1 - \frac{\sum_{i=1}^N \{y_i - \hat{c}(x_i)\}^2}{\sum_{i=1}^N (y_i - \tilde{y})^2} = 1 - \frac{149.0}{297.4} \cong 0.5$$

相関係数

$$R = \sqrt{R^2} = \sqrt{0.5} \cong 0.706$$

# 正則化

对于泛化能力强的线性回归方程来说，输入变化小，输出变化也小；  
如果权重过大，就会导致输入变化小但输出变化大  
所以要让尽可能多的系数为零，并最小化非零系数  
这时候就需要正则化

## □ 望ましい線形回帰式

- 汎化能力という点では、入力が少し変化したときに、出力も少し変化する回帰式が良い

- 重みが大きいと、入力が少し変化するだけで出力が大きく変化
- そのような回帰式は、たまたま学習データの近くを通っても、未知データに対する出力は信用できない

しんよう

- 線形回帰の重みは、値が0となる次元を多くすれば良い

- 回帰式の係数 $w$ に関して、「大きな値の重みが、なるべく少なくなる」あるいは「0となる重みが多くなる」ような方法が必要

くふう

- このような工夫が**正則化** 在误差函数中加入正则化项

ついか

- 誤差関数の式に正則化項を追加する

# 正則化 : Ridge回帰

## □ Ridge回帰

- パラメータ $\mathbf{w}$ の二乗を正則化項とする
- パラメータの値が小さくなるように正則化させる

$$E(\mathbf{w}) = (\mathbf{y} - \mathbf{X}\mathbf{w})^T (\mathbf{y} - \mathbf{X}\mathbf{w}) + \lambda \mathbf{w}^T \mathbf{w}$$

正則化項

$\lambda$  : 正則化項の重み (重みが大きければ、性能よりも正則化の結果を重視)  
权重越大越重视正则化

- 最小二乗法でパラメータを求めたときと同様に、 $\mathbf{w}$ で微分した値が0となる $\mathbf{w}$ の値を求めると...

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$$

※  $\mathbf{I}$  : 単位行列 たんい

# 正則化：Lasso回帰

## □ Lasso回帰

- パラメータ $\mathbf{w}$ の絶対値を正則化項とする
- 値を0とするパラメータが多くなるように正則化される

$$E(\mathbf{w}) = (\mathbf{y} - \mathbf{X}\mathbf{w})^T (\mathbf{y} - \mathbf{X}\mathbf{w}) + \lambda \sum_{j=1}^d |w_j|$$

权重越大为零的系数越多

$\lambda$ ：正則化項の重み（大きければ、値を0とする重みが多くなる）

$w_0$ ：回帰式の切片は汎化能力に影響なし（通常は正則化の対象としない）

不影响泛化能力，一般不作为正則化対象

- Lasso回帰の解は、解析的に求められない

- 原点で微分不可能な絶対値を含むため
- 正則化項の上限を微分可能な2次関数で押さえ、その関数のパラメータを誤差が小さくなるように逐次更新する方法が提案


# 正則化：正則化の振る舞い

## □ Ridge回帰 系数被限制在一个超球中


- パラメータの存在する範囲を円（ $d$ 次元では超球）の中に限定して、それぞれの重みが大きな値をとれないようにする
  - 重み：誤差関数の等位線との接点（＝円周上の点）

## □ Lasso回帰 限定系数和一定

- パラメータの和が一定という条件なので、それぞれの軸で角をもつ領域に値が制限
  - 角で誤差関数の等位線と接する（多くのパラメータが0になる）



Ridge回帰における  
正則化



Lasso回帰における  
正則化

# バイアスと分散のトレードオフ

- 回帰式を高次方程式に置き換えて適用できる
  - 特徴ベクトル $x$ に対して、基底関数ベクトル $\phi(x)$ を考える
$$\phi(x) = (\phi_1(x), \dots, \phi_b(x))^T$$
    - 例：1次元ベクトル $x$ に対して  $\phi(x) = (1, x, x^2, \dots, x^b)^T$ となる
  - 以下のように回帰式を定義すれば、係数が線形という条件のもとで最小二乗法が適用可能

$$\hat{c}(x) = \sum_{j=0}^b w_j \phi_j(x)$$

- 複雑な関数を用いることで、  
真のモデルに近い形を表現できるのか？

# バイアスと分散のトレードオフ

trade off  
□ バイアスと分散はトレードオフの関係

bias ■ バイアス：真のモデルとの距離 与真实模型的距离  
■ 分散：学習結果の散らばり具合 学习结果的分散情况  
方差越小，当输入变化时输出变化越小

□ 単純なモデル → バイアス：大、分散：小

こべつ  
■ 個別のデータに対する誤差が大きくなりやすいが、学習データが少し変動しても結果として得られるパラメータは大きく変動しない  
へんどう

□ 複雑なモデル → バイアス：小、分散：大

■ 個別のデータに対する誤差を小さくしやすいが、学習データの値が少し変動すると、結果が大きく異なることがある



# バイアスと分散のトレードオフ

## □ 回帰問題における**バイアスと分散**

### ■ **線形回帰式**の場合

- 求めた超平面は、学習データ内の点をほとんど通らないので、バイアスが大きい

### ■ 「**学習データの個数 - 1**」次の**高次回帰式**の場合

- 求めた回帰式は、全学習データを通る（学習データと一致する関数が求まる）ので、バイアスが小さい
- データが少し動いただけで、この高次式は大きく変動するので、結果の分散は大きい

## □ **機械学習では、バイアスー分散のトレードオフを常に意識しなければならない** **正則化能够有效降低方差**

### ■ **正則化**： **緩いバイアスで分散を減らすのに有効**

# 回帰木

## □ 回帰木 回归树: 节点为特征, 叶子为输出值

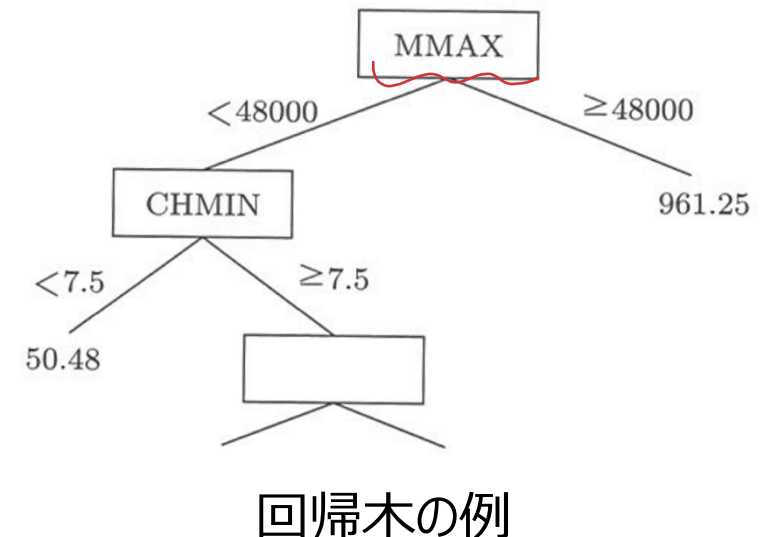
- 識別における決定木の考え方を回帰問題に適用する方法

## □ 決定木による識別問題の学習

- 特徴の値によって学習データを同じクラスの集合になるように分割する

## □ 回帰木による回帰問題の学習

- 出力値の近いデータが集まるように、特徴の値によって学習データを分割
- 特徴をノードとし、出力値をリーフとする回帰木が得られる



# 回帰木 : CART

## □ CART (classification and regression tree)

- 木の構造を二分木に限定した決定木 (限定为二叉树)
- 分類基準 : ジニ不純度 (Gini impurity) 分類标准

## □ CARTによる識別問題 选择G变化值最大的分类

- 分類前後の集合のジニ不純度 $G$ を求めて、改善度 $\Delta G$ が最大のものをノードに選ぶことを再帰的に繰り返す

$$G = 1 - \sum_{j=1}^c N(j)^2$$

$$\Delta G(D) = G(D) - P_L \cdot G(D_L) - P_R \cdot G(D_R)$$

$D$  : あるノードに属するデータの全体  
 $N(j)$  : データ中のクラス $j$ の割合

$D_L$  : 左の部分木 ( $D_R$ は右の部分木)  
 $P_L$  :  $D_L$ に属するデータの割合 ( $P_R$ は $D_R$ に属する)

# 回帰木：CART

□ CARTによる回帰問題 选择SS减少量最大的分类

- 分類基準として、データの散らばりSSの減り方 $\Delta SS$ が最大になるものを選択 实际上就是寻找方差最小的划分

$$SS(D) = \sum_{y_i \in D} (y_i - \tilde{y})^2$$

$$\Delta SS(D) = SS(D) - P_L \cdot SS(D_L) - P_R \cdot SS(D_R)$$

$\tilde{y}$  :  $D$ に属するデータの平均値  
 $D$  : あるノードに属するデータの全体

$D_L$  : 左の部分木 ( $D_R$ は右の部分木)  
 $P_L$  :  $D_L$ に属するデータの割合 ( $P_R$ は $D_R$ に属する)

$SS(D)$ では、データ $D$ の分散を求めているので、  
この基準は分割後の分散が最小となるような分割を求めている

# 回帰木：モデル木

1. 选取特征划分相似数据

2. 对叶子中数据计算线性回归方程

## □ モデル木 叶子节点为线性回归方程

### ■ 回帰木のリーフの値を線形回帰式とした木

- 回帰木と線形回帰の双方の利点（そうほうりてんい）を活かした方法

### ■ モデル木の生成手順

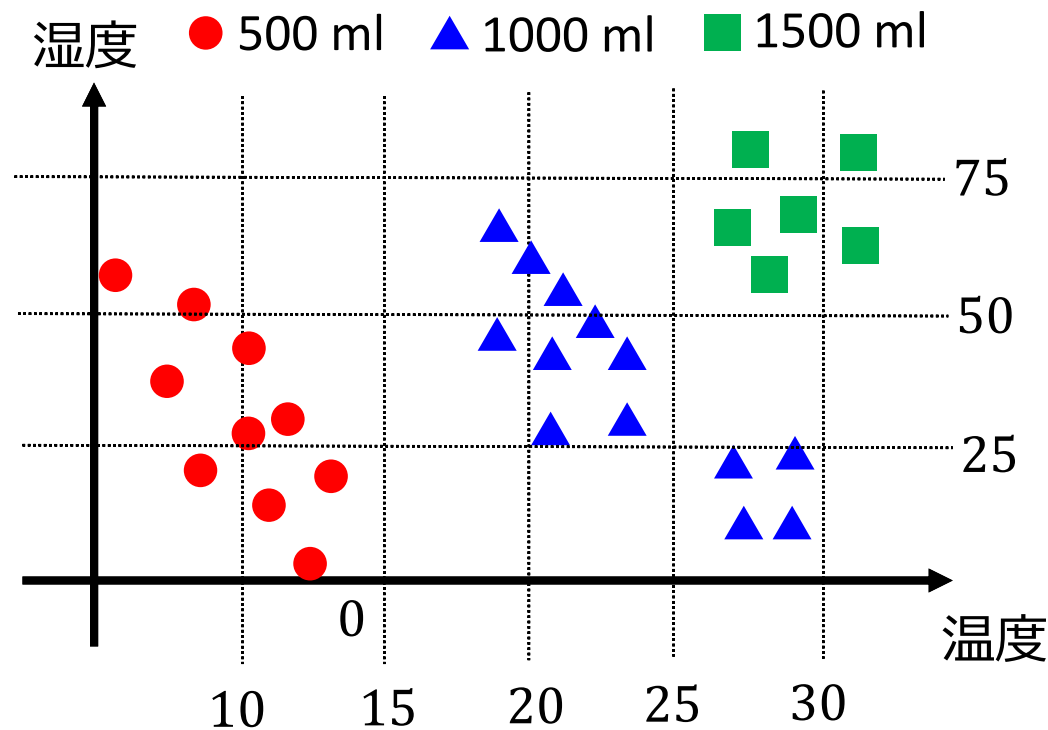
1. 出力値が近い区間を切り出せる特徴を選んでデータ分割
2. 分割後のデータに対して線形回帰式を計算

### ■ 特定の要因（よういん）によって振る舞いが異なるデータを分割し、それぞれに対応する規則性を見つけ、かつ、その分割の要因を木構造によって説明できる

- 例えば、季節（きせつ）によって出力に影響（およ）を及ぼす要因が異なるデータなどに有効

# 演習問題6-2（10分間）

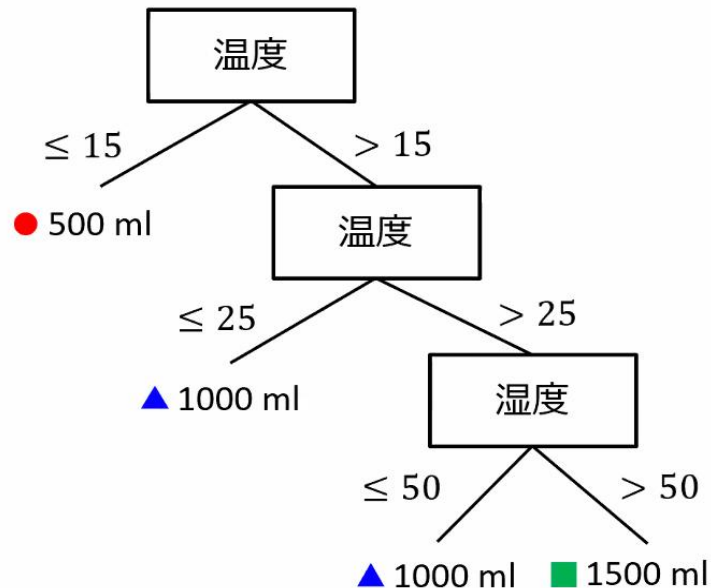
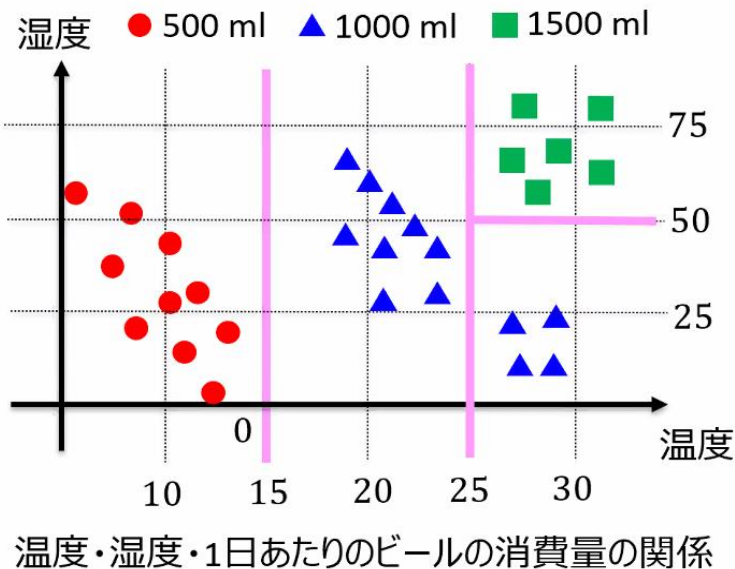
- 以下の学習データが与えられたとき、温度と湿度から1日あたりのビールの消費量を予測する回帰木を作成せよ



温度・湿度・1日あたりのビールの消費量の関係

# 演習問題6-2（10分間） 解答例

出力値の近いデータが集まるように、  
特徴の値によって学習データを分割するのがポイント



回帰木には3つのノードがあります：

1. 温度が15より大きいかどうかに応じて分割します；
2. 温度が25を超えるかどうかに応じて分割します；
3. 湿度が50より大きいかどうかに応じて分割します。